APPLICATIONS & TOOLS

1 de abril de 2026 15:41

Pipeline de Machine Learning

1. **Dados (Data)** : informação em bruto recolhido de várias fontes (bases de dados, folha de cálculo, etc.). Inclui as "**features**" (variáveis) que descrevem o problema.
2. **Algoritmo / Modelo** : a técnica de **ML** escolhida (ex: Árvores de Decisão, Redes Neuronais) que é treinada com os dados históricos para aprender padrões.
3. **Previsões (Predictions)** : o **resultado** final (output) gerado pelo modelo.

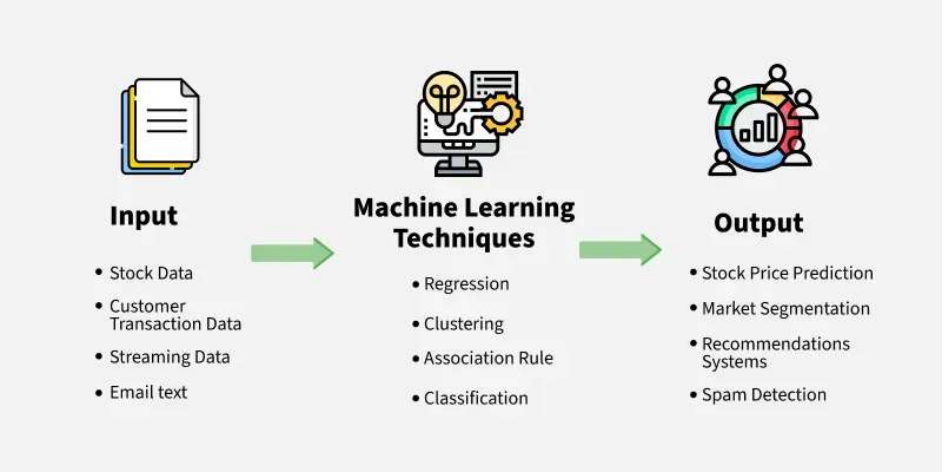

Tipos de Problemas de ML

Classificação (**Aprendizagem Supervisionada**) : objetivo é **prever** uma **categoria discreta**, o modelo aprende através de dados históricos rotulados.

- **Binária** (Fraude vs Não Fraude)
- **Multiclasse** (Cão, Gato, Peixe)
- **Multirrótulo** (Múltiplas tags num artigo)

Regressão (**Aprendizagem Supervisionada**) : objetivo é **prever** um valor **numérico contínuo**, estimando uma quantidade. Ex: previsão do preço de casas ou meteorologia.

Clustering (**Aprendizagem Não-Supervisionada**) : objetivo é **agrupar pontos de dados semelhantes** sem usar rótulos predefinidos,

descobre padrões escondidos por si mesmo. Ex: segmentação de clientes.

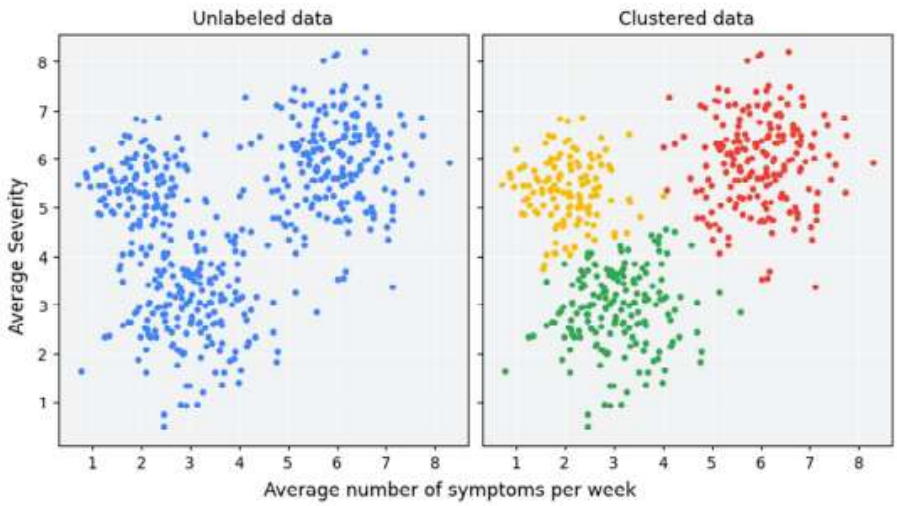

Plataformas de No-Code / Low-Code ML

Plataforma	Descrição	Prós	Contras	Como Testar
Google Cloud Vertex AI	Plataforma cloud unificada do Google para criar, treinar e implementar modelos (AutoML e LLMs).	Integração profunda no ecosistema Google (BigQuery); Escalável para o nível empresarial.	Curva de aprendizagem maior; Pode ser dispendioso.	Créditos grátis na Google Cloud e limite de uso gratuito.
DataRobot	Plataforma automatizada de ML (AutoML) muito orientada para negócios.	Excelente "explainability" (XAI); Governança de modelos robusta.	Caro (foco empresarial); Ambiente proprietário e com pouca customização manual.	Período de avaliação de 30 dias.
Obviously AI	Plataforma incrivelmente simples,	Muito intuitiva; Excelente	Poucas opções de *tuning*	Avaliação gratuita por tempo limitado.

	onde utilizadores interagem usando linguagem natural.	para predições de negócios rápidas.	avançado; Menor ecossistema de integração.	
BigML	Plataforma cloud com workflows visuais, muito usada no ensino.	Ampla gama de algoritmos; Modelos transparentes e fáceis de documentar.	Interface algo datada; Limitações no suporte a *Deep Learning*.	Avaliação gratuita permanente (dataset limitado a 16MB).
Microsoft Azure ML Studio	Ambiente de "arrastar e largar" integrado na Microsoft, com recursos de AutoML.	Combina ferramentas visuais com *notebooks*; Ótima integração com PowerBI e SQL.	Licenciamento complexo; Recursos avançados ainda exigem código.	Conta gratuita Azure (12 meses).
AWS SageMaker & Canvas	O SageMaker é para ML à escala; O Canvas é a versão visual *no-code* focada em analistas de negócio.	ML sem código mas é com o poder do ecosistema AWS e conectores para S3/Redshift.	Pode tornar-se muito caro rapidamente; Requer configuração de contas e permissões IAM.	*Free Tier* da AWS (uso limitado).
Orange Data Mining	Ferramenta visual de "arrastar e largar"	100% Gratuito; Visualizações e	Não otimizado para *Big Data* ou	Download gratuito em *orangedataminin g.com*.

	Open-Source, excelente para pesquisa e educação.	extensões muito úteis (Texto, Bioinformática).	implementação automatizada em escala.	

Dados como o "Novo Petróleo"

Tal como o petróleo impulsionou a revolução industrial, os dados são a força vital da economia digital.

- **Diferença crucial** - ao contrário do petróleo (finito e de transporte físico), os dados são **infinitos, facilmente replicáveis e distribuídos a baixo custo** para qualquer indústria.

- **Revolução IA** - explosão massiva de dados combinada com o poder de computação (GPUs) está a impulsionar a revolução da IA.

- **Desafios** - uso massivo de dados exige infraestruturas complexas (cloud) e traz grandes desafios éticos e de **privacidade/segurança** (ex: RGPD).

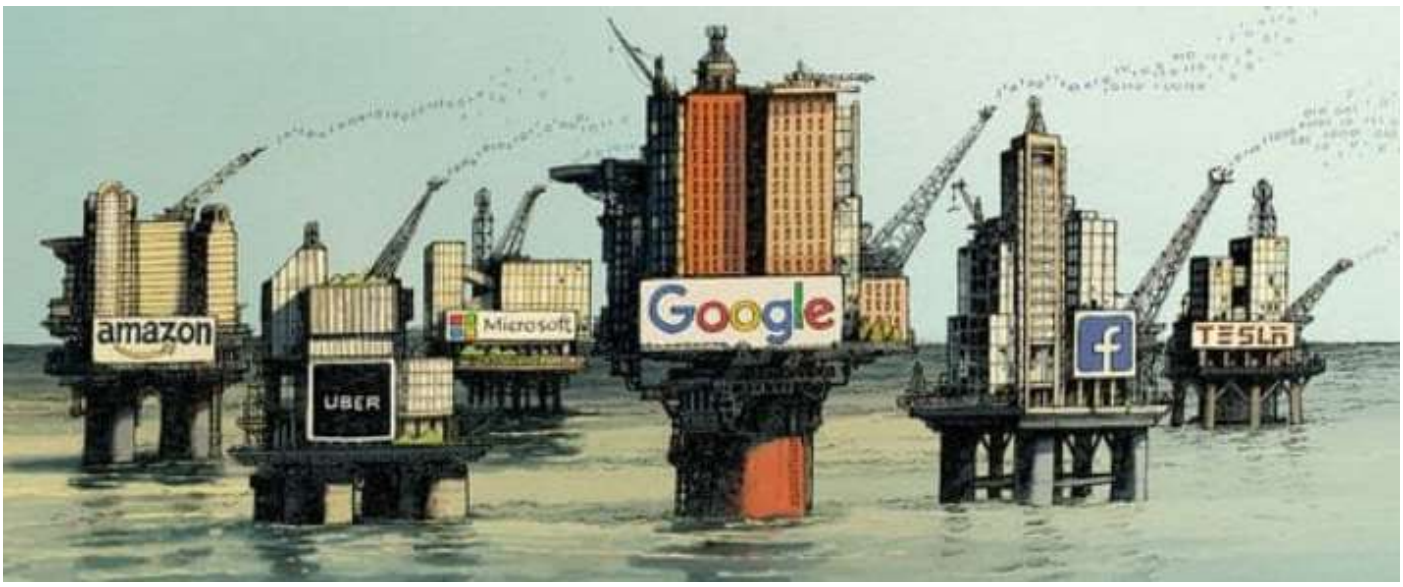

O que É (e NÃO É) uma Organização Data-Driven

- **É** - empresa que toma decisões **baseadas em dados e evidências concretas**, em vez de se basear em intuição ou suposições (Assimptions). Segue o princípio **MAD** (Measure, Analyse, Decide).

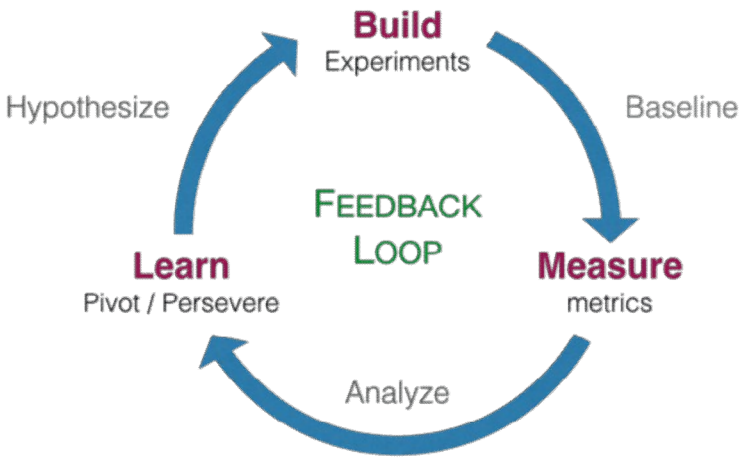

- **NÃO É** - ter dezenas de relatórios, dashboards e alertas não faz de uma empresa Data-Driven.

HIPPO (Highest Paid Person's Opinion) - uma verdadeira cultura de dados tenta combater, as decisões devem ser guiadas pelos dados, não pela opinião da pessoa mais bem paga da sala

Fé Cega - ser data-driven **não significa seguir os dados cegamente**, o raciocínio crítico humano é essencial

Cadeia de Valor e a Cultura de Dados

Os dados não têm valor sozinhos, eles precisam de passar pela Cadeia de Valor da Analítica:

- **Data -> Information -> Analysis -> Action -> Value** (Nota: Se a análise não gerar uma "Action", não se extrai "Value")

A empresa precisa de uma **Cultura Data-Driven**, assente em pilares como:

- **Goals First** - defini os **objetivos de negócio primeiro**, e só depois procurar os dados/ferramentas para os atingir.

- **Broad Data Literacy** - toda a **equipa** deve saber **ler, entender e comunicar com dados**

- **Open / Sharing** - fim dos silos de dados, **juntar dados de várias fontes para ter contexto**.

- **Self Service (A Ilusão do "Unicórnio)** - **nenhum indivíduo** domina **todas as áreas**, logo é preciso uma **equipa multidisplinar**

- **Testing** - inovar através de experimentação contínua (**testar hipóteses e falhar rápido**)

- **Data Leadership** - Top-down (líderes) e bottom-up (todos os empregados)

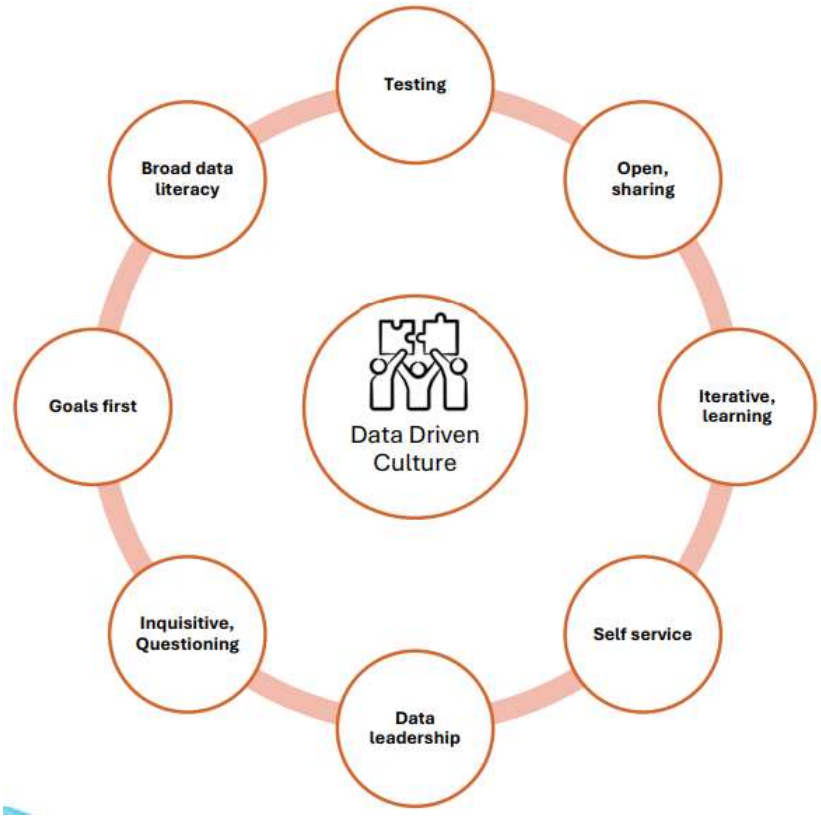

4 Tipos de Análise de Dados (Analytics)

1. **Descritiva (O que aconteceu?)** - olha para o **passado** (ex: relatórios, dashboards de vendas).

2. **Diagnóstica (Porquê que aconteceu?)** - procura as **causas** (ex: drill-down, análise de tendências).

   ! a. Correlação NÃO É Causalidade (ex: vendas de gelados e homicídios sobem no verão, mas um não causa o outro).

3. **Preditiva (O que é provável que aconteça?)** - usa modelos estatísticos/IA para estimar probabilidades futuras. Não garante o futuro, **prevê probabilidades**.

4. **Prescritiva (O que devemos fazer?)** - o nível mais avançado, **simula cenários e recomenda** a melhor ação para otimizar um resultado.

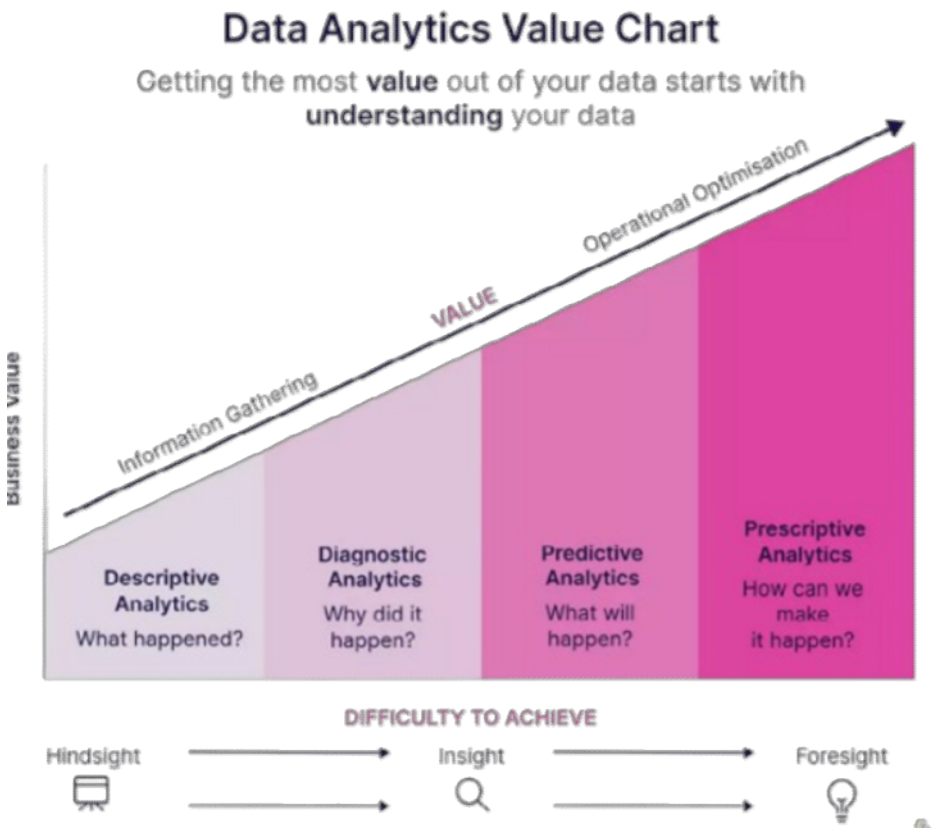

Analista "Business Savvy"

As competências técnicas (programação, matemática) não chegam. Um excelente analista precisa de **Business Savvy** (Visão de Negócio).

- **Características** - compreende o contexto do negócio, foca-se no impacto real, é proativo (antecipa problemas), e atua como um **"tradutor"** entre os dados técnicos e as decisões estratégicas dos gestores.

Abordagem Data-Driven (Orientada a Dados)

Utilização sistemática de dados para orientar todas as operações e decisões numa organização, substituindo a intuição.

Decisões Orientadas a Dados (DDDM) - processo de fazer escolhas estratégicas com base na análise dos dados. Ex: Netflix - utiliza dados sobre o que os utilizadores assistem e pesquisam para o seu sistema de recomendação.

Evolução da Cultura de Dados (Os 5 Estágios)

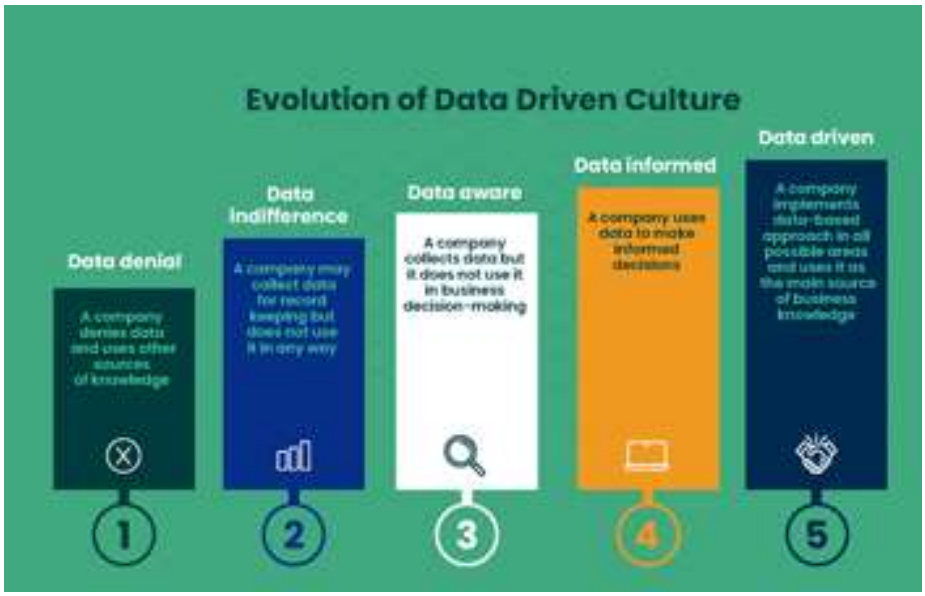

1. **Data Denial (Negação)** - ignora os dados e **confia apenas na intuição** ex: pequenos negócios familiares

2. **Data Indifference (Indiferença)** - dados **guardados** para registo, mas **não são usados** nas decisões

3. **Data Aware (Consciente)** - **recolhe dados**, mas ainda não têm impacto prático nas escolhas estratégicas

4. **Data Informed (Informada)** - **dados já influenciam as decisões**, servindo de apoio, mas ainda se **misturam com a intuição**

5. **Data Driven (Orientada a Dados)** - **cultura é totalmente baseada em dados**, que geram decisões e conhecimentos em todas as áreas ex: Amazon, Google, Netlix

Infraestrutura de Dados - fundação que permite criar, gerir, usar e proteger os dados, **garantindo que a informação certa chega aos sistemas certos** , ex: manter o fluxo de dados, garantir a sua qualidade e evitar "silos de dados", informação isolada para outro departamento.

Data Warehouse (Armazém de Dados) - **guarda dados estruturados** que já foram processados e limpos, ideal para BI e relatórios históricos, custo : Alto.

Data Lake (Lago de Dados) - **guarda dados brutos (raw)** no seu formato original (estruturado ou não), ideal para explorar padrões escondidos e análises avançadas, custo : Baixo/Económico.

Data Lakehouse - **junta a flexibilidade do Lake com as estruturas do Warehouse**, suporta dados brutos, mas permite organizá-los, <u>excelente para integrar IA e Machine Learning</u> no mesmo ambiente dos dados.

Arquitetura do Lakehouse (As 3 Zonas)

- **Bronze (Landing Zone)** - ingestão de dados na sua **forma mais bruta** (Raw)

- **Silver (Staging Zone)** - os **dados são filtrados, limpos** e melhorados

- **Gold (Curated Zone)** - **dados agregados, de alta qualidade**, prontos para consumo do negócio, relatórios e modelos de IA

Business Analytics (BA) - transforma dados em insights acionáveis para guiar decisões inteligentes

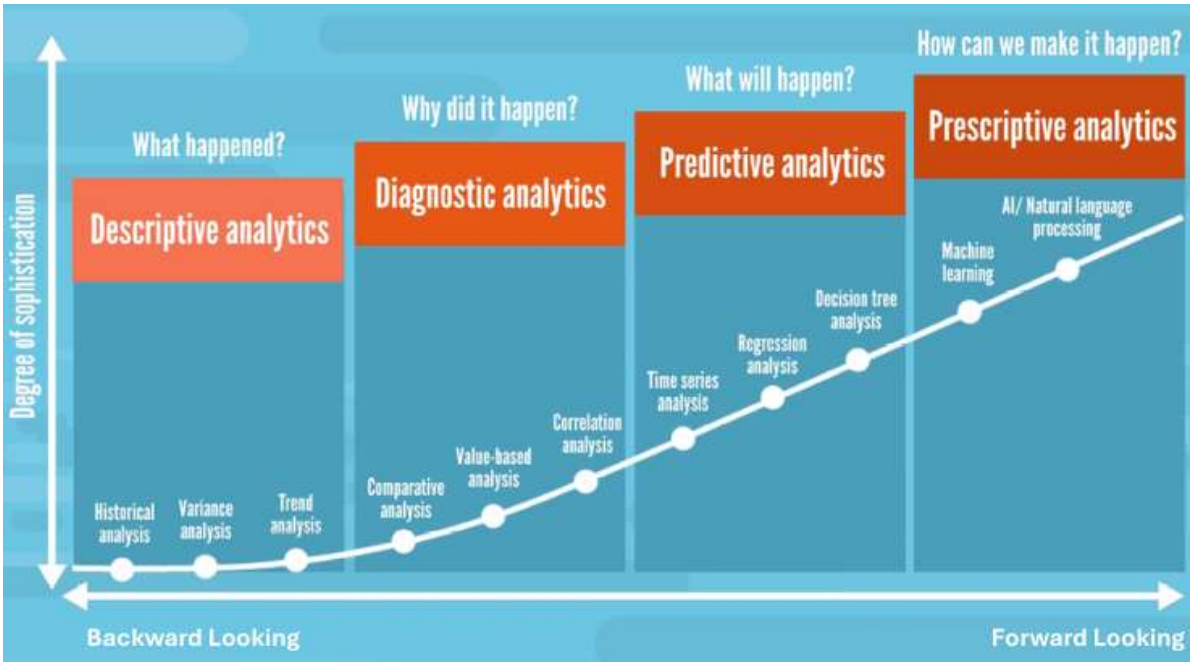

- **Descriptive & Diagnostic Analytics (O que aconteceu? / Porque aconteceu?)** - **analisa dados históricos** para explicar tendências e variâncias ex: dashboard que mostra a faturação caiu 10%, fazer análise SWOT

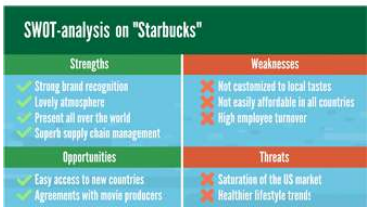

- **Predictive Analytics (O que vai acontecer?)** - usa modelos estatísticos e machine learning para **prever o futuro**.

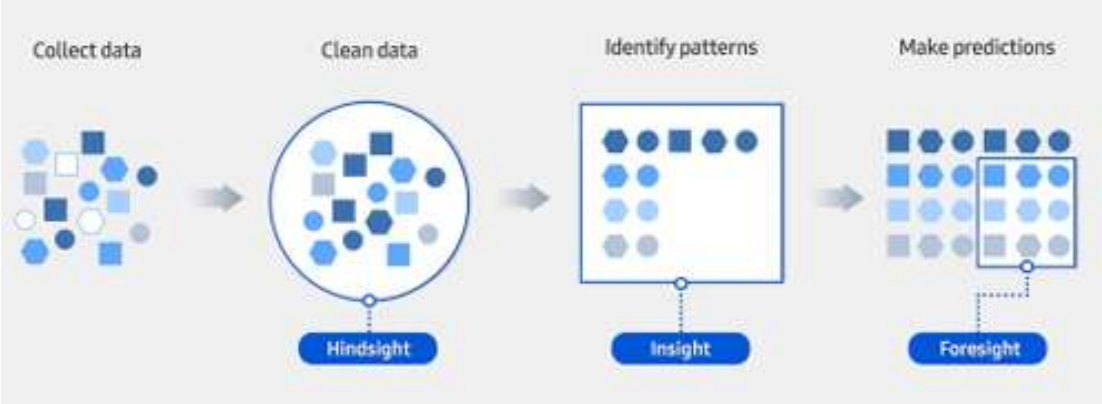

- **Prescriptive Analytics (Como fazemos acontecer?)** - nível mais avançado, recomenda a melhor ação a tomar para uma determinda situação, ex: **GPS que não só prevê o trânsito (Predictive), mas recomenda ativamente um desvio para poupar tempo.**

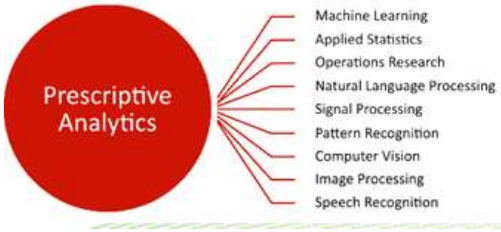

Mundo das Métricas: KPIs, KBIs e KRIs

"Nem todas as métricas são KPIs, mas todos os KPIs são métricas".

- **KPIs (Key Perfomance Indicators)** - foco no desempenho, **analisam o passado/presente** ex: taxa de crescimento de Receita (Revenue Growth Rate), Quota de Mercado (Market Share), Índice de Satisfação do Cliente (CSI)

- **KBIs (Key Business Indicators)** - **foco puramente financeiro**, preveem e monitorizam a saúde financeira da empresa ex: Margem de Lucro (Profit Margin), Custo de Aquisição de Ciente (CAC), Valor do Tempo de Vida do Cliente (CLV)

- **KRIs (Key Risk Indicators)** - **sinais de alerta** precoce para **potenciais riscos** internos ou externos ex: Taxa de Rotação de Colaboradores (Employee Turnover Rate), Taxa de Incidentes de Cibersegurança, Dias de Vendas Pendentes (DSO - risco de liquidez)

Business Analytics (BA) vs Business Intelligence (BI)

Business Intelligence (BI) - focado no **passado e presente**, usa reporting, dashboards e visualizações para resumir dados históricos ex: o que vendemos ontem?

Business Analytics (BA) - focado no **futuro**, usa estatística avançada, data mining e ML para prever resultados e prescrever ações ex: o que vamos vender amanhã?

Business Analytics vs Big Data Analytics

Business Analytics - lida maioritariamente com **dados estruturados**, usa ferramentas como SQL e plataformas de BI

Big Data Analytics - lida com **dados massivos e complexos**, como posts de redes sociais, vídeos, sensores, é guiado pelos 5 V's

Os 5 V's do Big Data

- **Volume:** a escala pura dos dados
- **Velocidade:** a rapidez com que os dados chegam e são processados

- **Variedade:** evoluímos de tabelas para vídeo, áudio, JSON etc

- **Veracidade:** a capacidade de limpar e confiar no dado, qualidade

- **Valor**: os outros 4 V's não servem se não tirarmos lucro ou insights úteis.

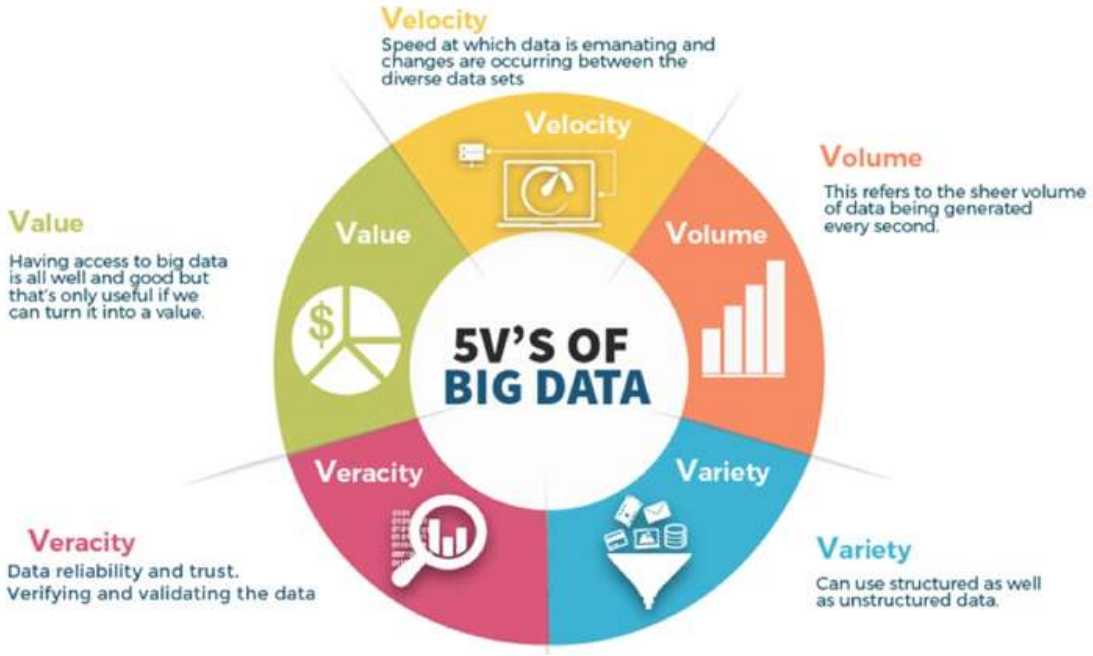

CRISP-DM - metodologia mais utilizada no mundo para projetos de Data Science e Data Mining, **ajuda a tornar os projetos fiáveis**, repetíveis e não depende de nenhuma ferramenta, indústria ou software (é neutra).

As 6 Fases do CRISP-DM

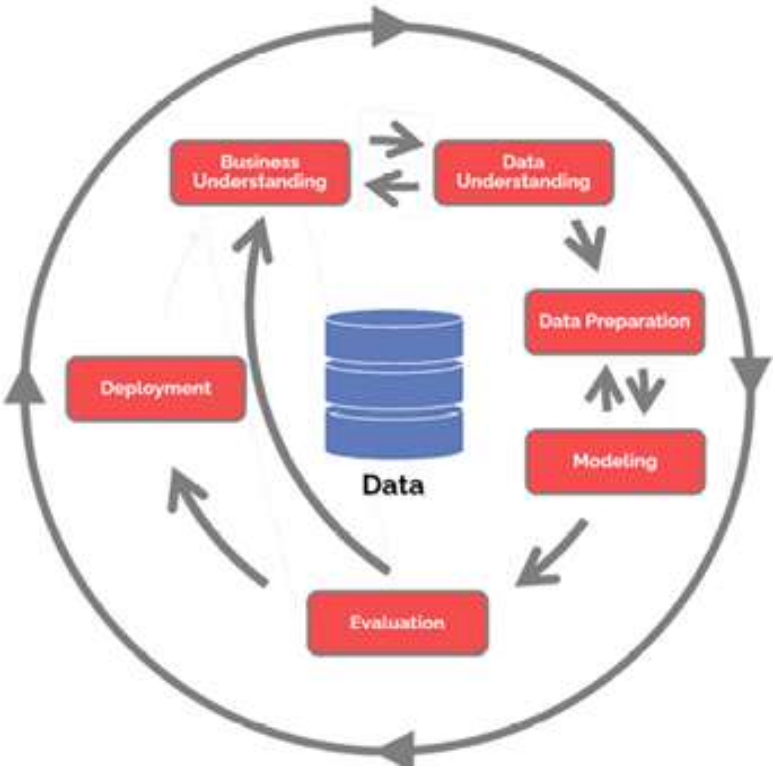

Business Understanding	Data Understanding	Data Preparation	Modeling	Evaluation	Deployment
Determine Business Objectives *Background* *Business Objectives* *Business Success Criteria* **Assess Situation** *Inventory of Resources* *Requirements, Assumptions, and Constraints* *Risks and Contingencies* *Terminology* *Costs and Benefits* **Determine Data Mining Goals** *Data Mining Goals* *Data Mining Success Criteria* **Produce Project Plan** *Project Plan* *Initial Assessment of Tools and Techniques*	**Collect Initial Data** *Initial Data Collection Report* **Describe Data** *Data Description Report* **Explore Data** *Data Exploration Report* **Verify Data Quality** *Data Quality Report*	**Select Data** *Rationale for Inclusion/ Exclusion* **Clean Data** *Data Cleaning Report* **Construct Data** *Derived Attributes* *Generated Records* **Integrate Data** *Merged Data* **Format Data** *Reformatted Data* *Dataset* *Dataset Description*	**Select Modeling Techniques** *Modeling Technique* *Modeling Assumptions* **Generate Test Design** *Test Design* **Build Model** *Parameter Settings* *Models* *Model Descriptions* **Assess Model** *Model Assessment* *Revised Parameter Settings*	**Evaluate Results** *Assessment of Data Mining Results w.r.t. Business Success Criteria* *Approved Models* **Review Process** *Review of Process* **Determine Next Steps** *List of Possible Actions* *Decision*	**Plan Deployment** *Deployment Plan* **Plan Monitoring and Maintenance** *Monitoring and Maintenance Plan* **Produce Final Report** *Final Report* *Final Presentation* **Review Project** *Experience Documentation*

Fase 01 : Business Understanding (Compreensão do Negócio)

- **Entender o que o cliente/empresa quer** e converter esse <u>objetivo de negócio num objetivo técnico</u> de Data Mining, define-se o plano, recursos, riscos e critérios de sucesso ex: reter clientes, criar um modelo para prever a saida de um cliente com

base no histórico.

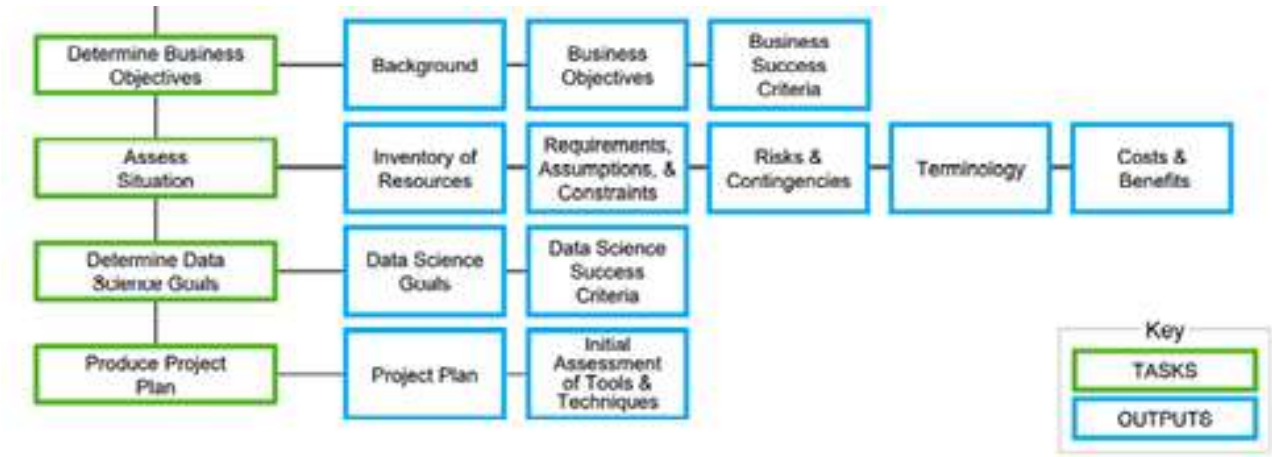

Fase 02 : Data Understanding (Compreensão dos Dados)

- **Recolher dados iniciais**, explorá-los e **verificar a sua qualidade** ex: banco extrai os dados, repara que faltam algumas idades de clientes e analisa estatísticas básicas.

Fase 03 : Data Preparation (Preparação dos Dados)

- **Constrói o dataset final**, inclui <u>selecionar, limpar, integrar e formatar os dados e criar novos atributos</u> ex: o banco apaga clientes que não têm morada (limpeza), junta a BD de marketing com a financeira (integração) e calcula a média de gastos por mês de cada um (novo atributo).

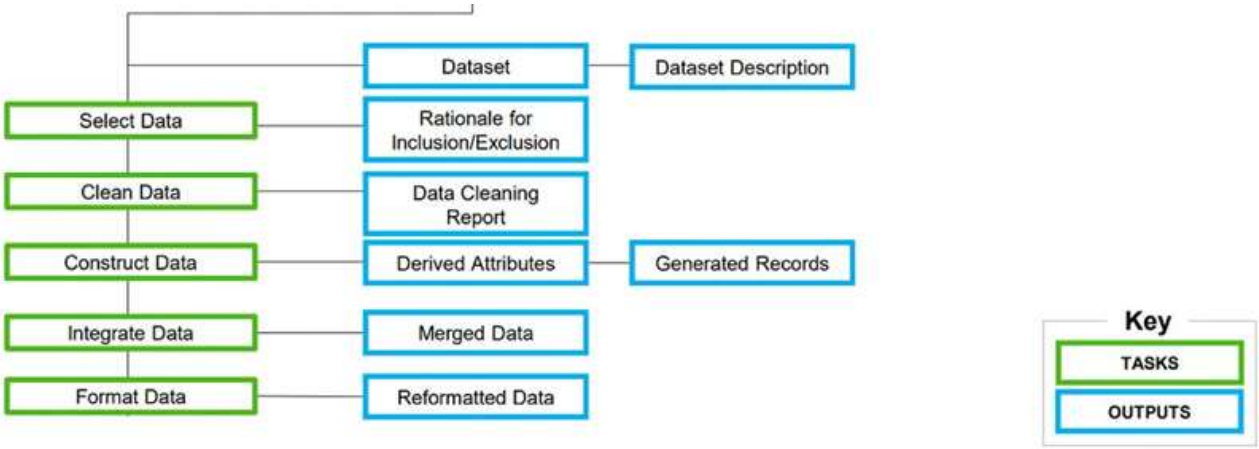

Fase 04 : Modeling (Modelação)

- **Escolher o algoritmo** (ex: regressão, neural network), dividir os dados em treino e test e contruir o modelo e fazer uma **avaliação técnica inicial**. Data Science treina um modelo de classificação e conclui que ele tem 90% de precisão a detetar quem vai sair do banco.

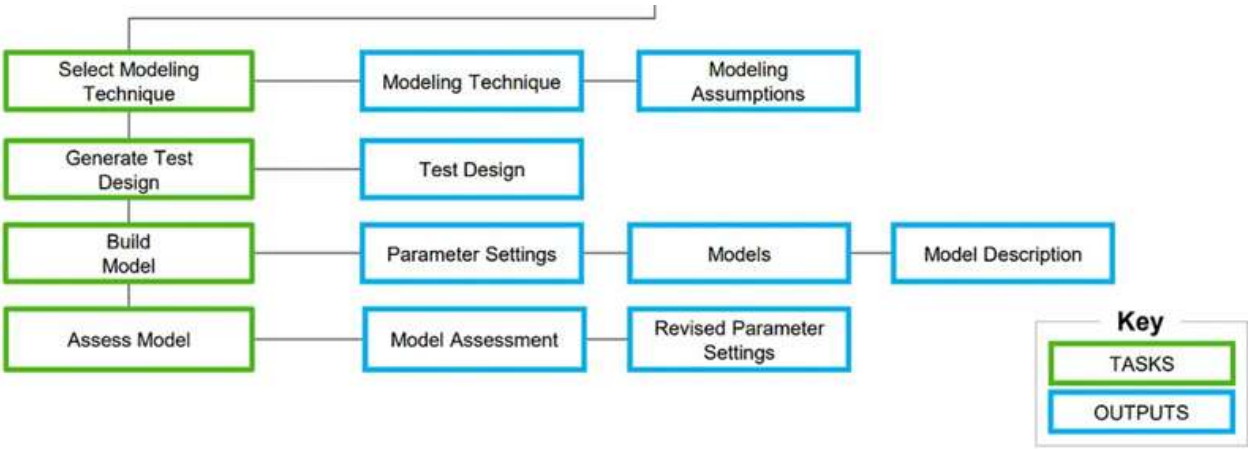

Fase 05 : Evaluation (Avaliação)

- **Avaliar se o modelo cumpre os objetivos de negócio definidios na Fase 01** (perceber se não é apenas bom tecnicamente), rever o processo e **tomar a decisão final.**

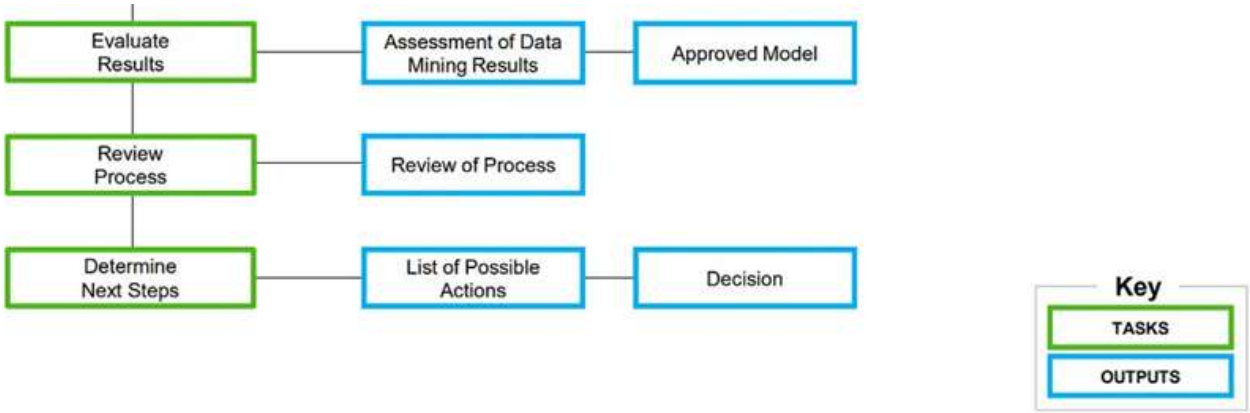

Fase 06 : Deployment (Implementação/Integração)
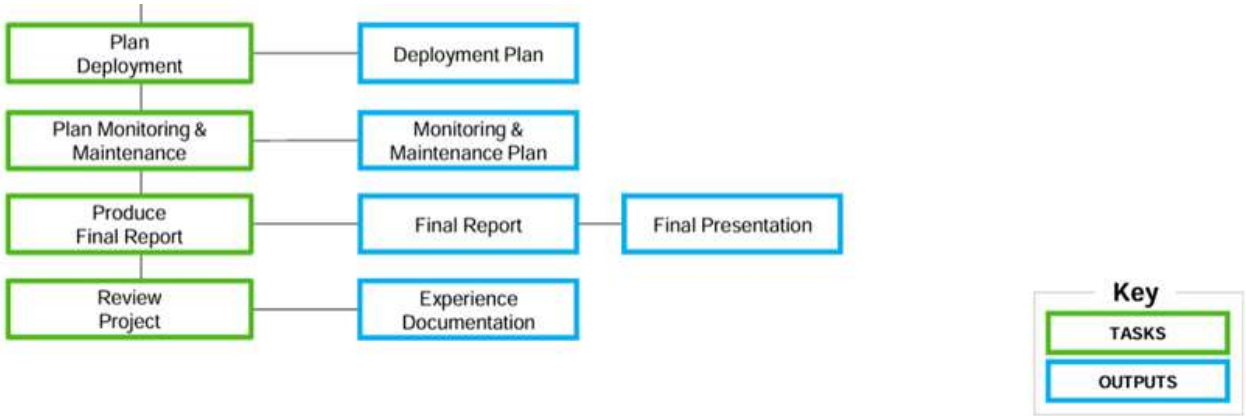
- **Colocar o modelo a uso prático**, criar o plano de monitorização/manutenção e o relatório final.