

✓ 1 Introduction to Time Series Forecasting

No contexto de configuração de dados, qual é a principal distinção entre uma abordagem de previsão univariada e uma multivariada?

- ☐ **A.** A univariada foca apenas no histórico de y , enquanto a multivariada utiliza y e variáveis externas (Features).
- ☐ **B.** A univariada utiliza apenas variáveis estáticas, enquanto a multivariada foca em variáveis dinâmicas.
- ☐ **C.** A univariada é utilizada apenas para treinos locais, enquanto a multivariada é exclusiva para treinos globais.
- ☐ **D.** A univariada gera apenas Point Forecasts, enquanto a multivariada gera Previsões Probabilísticas.

Como são classificadas as variáveis que não sofrem alterações ao longo do tempo, como o ID de uma loja ou de um produto?

- ☐ **A.** Variáveis de Drift
- ☐ **B.** Features Estáticas
- ☐ **C.** Variáveis de Target
- ☐ **D.** Features Dinâmicas

Qual é a principal limitação associada ao uso exclusivo de 'Point Forecast' em previsões de séries temporais?

- ☐ **A.** Ignora completamente o risco e a incerteza associados à previsão.
- ☐ **B.** Não pode ser utilizado em modelos de treino global.
- ☐ **C.** Exige obrigatoriamente o uso de features dinâmicas.
- ☐ **D.** É computacionalmente mais lento do que as previsões probabilísticas.

Em previsões probabilísticas, o que representam os limites P10 e P90?

- ☐ **A.** O intervalo entre o pior cenário esperado e o teto máximo da previsão.
- ☐ **B.** A média e a mediana da distribuição, respetivamente.
- ☐ **C.** A percentagem de dados utilizada para treino e validação.
- ☐ **D.** O erro absoluto mínimo e máximo tolerado pelo modelo.

Qual é a vantagem crítica do 'Treino Global' em comparação com o 'Treino Local'?

- ☐ **A.** Capacidade de aprender padrões gerais através de múltiplas séries (Cross-Learning).
- ☐ **B.** Garante que a amostra de teste seja sempre menor que o horizonte de previsão.
- ☐ **C.** Eliminação total da necessidade de métricas de escala como o MASE.
- ☐ **D.** Velocidade de processamento superior devido ao modo offline.

De acordo com a 'Regra de Ouro' da validação, qual deve ser o tamanho da amostra de teste em relação ao horizonte de previsão (h)?

- ☐ **A.** O tamanho do teste deve ser exatamente igual a $h/2$.

- ☐ **B.** O tamanho do teste deve ser $\leq h$.
- ☐ **C.** O tamanho do teste deve ser $\geq h$.
- ☐ **D.** A amostra de teste deve ser fixa em 30 dias, independentemente de h .

Qual modelo baseline é caracterizado por projetar uma 'reta plana horizontal' baseada no último valor exato observado?

- ☐ **A.** Seasonal Naive
- ☐ **B.** Historic Average
- ☐ **C.** Naïve
- ☐ **D.** Drift

Por que é que o 'Seasonal Naïve' é frequentemente considerado um 'melhor baseline' do que o Naïve simples?

- ☐ **A.** Porque utiliza a média de todo o histórico para suavizar outliers.
- ☐ **B.** Porque é o único modelo que permite calcular o Prediction Interval (PI).
- ☐ **C.** Porque replica o comportamento do ciclo passado, capturando padrões sazonais.
- ☐ **D.** Porque incorpora a tendência de crescimento a longo prazo.

Qual das seguintes métricas é a mais indicada para comparar a performance de modelos entre séries temporais que possuem escalas completamente diferentes?

- ☐ **A.** MASE
- ☐ **B.** MAE
- ☐ **C.** MSE
- ☐ **D.** RMSE

Qual é a principal desvantagem da métrica MAPE (Mean Absolute Percentage Error)?

- ☐ **A.** É excessivamente resistente a outliers.
- ☐ **B.** Falha gravemente se existirem valores zero na série, devido à divisão por zero.
- ☐ **C.** Otimiza a média em vez da mediana.
- ☐ **D.** Não é uma métrica intuitiva para apresentações de negócio.

Se o seu objetivo principal é penalizar severamente grandes erros (outliers) no modelo, qual métrica deve priorizar?

- ☐ **A.** SQL
- ☐ **B.** WAPE
- ☐ **C.** MAE
- ☐ **D.** MSE / RMSE

A métrica WAPE é frequentemente preferida ao MAPE em contextos industriais porque:

- ☐ **A.** É ponderada pelo volume total da série, evitando distorções de baixos volumes.
- ☐ **B.** Garante que o modelo reaja muito mais aos outliers do que o RMSE.
- ☐ **C.** Otimiza a média em vez da mediana.

- ☐ D. É a única métrica que não sofre com a escala dos dados.

No contexto de incerteza, o que significa um 'Prediction Interval (PI)' muito largo?

- ☐ A. Existe muita incerteza quanto ao valor futuro.
- ☐ B. O modelo está a utilizar o baseline Historic Average.
- ☐ C. O modelo tem alta confiança na previsão exata ($P50$).
- ☐ D. O horizonte de previsão (h) é demasiado curto.

Para um gestor de stock, o limite superior $P90$ é crucial para monitorizar qual tipo de risco?

- ☐ A. Risco máximo de rotura de stock.
- ☐ B. Risco de a média ser inferior à mediana.
- ☐ C. Risco de excesso de stock acumulado.
- ☐ D. Risco de o erro absoluto ser maior que o MAE .

Qual das seguintes mnemónicas de sobrevivência ajuda a decidir quando usar Quantis (WQL, SQL)?

- ☐ A. Queres comparar séries? Usa a percentagem.
- ☐ B. Queres fugir aos outliers? Usa os absolutos.
- ☐ C. Queres a média? Usa os quadrados.
- ☐ D. Queres medir o risco? Usa os quantis.

Qual é a diferença fundamental entre as métricas SQL e WQL no que toca à escala?

- ☐ A. A SQL não sofre com a escala, mas a WQL sofre.
- ☐ B. Ambas sofrem severamente com a escala, tal como o MSE.
- ☐ C. Ambas são independentes da escala por serem métricas de quantis.
- ☐ D. A SQL sofre com a escala, enquanto a WQL não.

O modelo de baseline 'Drift' é visualmente representado por:

- ☐ A. Uma cópia exata do ciclo sazonal anterior.
- ☐ B. Uma reta no meio dos dados passados.
- ☐ C. Uma reta plana horizontal.
- ☐ D. Uma reta inclinada que sobe ou desce.

Por que razão o modelo de treino 'Local' é descrito como adequado para 'Treino Online'?

- ☐ A. Porque permite aprender com padrões de outras lojas em tempo real.
- ☐ B. Porque garante automaticamente que o erro RMSE seja minimizado.
- ☐ C. Devido à sua rapidez, permitindo atualizações frequentes e rápidas para uma única série.
- ☐ D. Porque utiliza menos features estáticas do que o treino Global.

Ao analisar a anatomia do Prediction Interval, qual valor é geralmente associado ao 'Point Forecast' exato?

- ☐ A. Média Aritmética
- ☐ B. $P10$

- ☐ C. P_{50}
- ☐ D. P_{90}

Se um modelo apresenta um erro MAE baixo mas um RMSE muito elevado, o que se pode concluir sobre os erros do modelo?

- ☐ A. O modelo é excelente para séries temporais com sazonalidade forte.
- ☐ B. O modelo comete poucos erros na maioria dos casos, mas comete alguns erros de magnitude muito grande.
- ☐ C. O modelo está a prever consistentemente com pequenos erros em todos os pontos.
- ☐ D. O modelo é enviesado para valores acima do real.

Qual é a lógica por trás do modelo baseline 'Historic Average'?

- ☐ A. Manter o último valor constante.
- ☐ B. Prever o valor do mesmo período no ano anterior.
- ☐ C. Calcular a média de todos os valores históricos observados.
- ☐ D. Seguir a tendência linear dos últimos dois pontos.

Uma previsão probabilística indica um P_{10} de 50 unidades. Como deve ser lido este limite inferior?

- ☐ A. O erro da previsão será de 10 unidades em 50% das vezes.
- ☐ B. O valor 50 é o Point Forecast (previsão exata).
- ☐ C. Há apenas 10% de probabilidade de o valor real cair abaixo de 50.
- ☐ D. Há 10% de probabilidade de o valor real ser superior a 50.

Qual o 'gatilho para o teste' quando se utiliza a métrica MAE?

- ☐ A. Ignorar picos extremos (outliers) e focar no erro absoluto médio.
- ☐ B. Medir exclusivamente o risco de rotura de stock.
- ☐ C. Penalizar fortemente os erros gigantes através da quadratura.
- ☐ D. Verificar se existem divisões por zero na série.

A mnemónica ' $\sqrt{x^2}$ ' refere-se a que tipo de objetivo na escolha de métricas?

- ☐ A. Otimizar a média através do uso de quadrados (MSE , $RMSE$).
- ☐ B. Capturar o risco de cauda da distribuição.
- ☐ C. Otimizar a mediana dos erros.
- ☐ D. Ignorar a escala para comparar modelos.

Em que cenário a métrica SQL (Scalable Quantile Loss) é considerada 'Exclusiva'?

- ☐ A. Para séries temporais sem qualquer histórico disponível.
- ☐ B. Para Previsões Probabilísticas, focando em quantis específicos.
- ☐ C. Para modelos baseline como o Seasonal Naive.
- ☐ D. Para avaliações de Point Forecast em treinos locais.

O que caracteriza o gráfico visual de um modelo baseline 'Seasonal Naïve'?

- ☐ A. Uma linha reta no meio da variação histórica.
- ☐ B. Uma linha reta horizontal partindo do último ponto.

- ☐ **C.** Uma linha que replica as subidas e descidas do ciclo anterior.
- ☐ **D.** Uma linha inclinada que ignora oscilações passadas.

Qual a principal diferença entre o treino Local e o treino Global no que toca à sua aplicação?

- ☐ **A.** O local é rápido e online; o global é lento e offline.
- ☐ **B.** O local foca em Point Forecast; o global foca em Incerteza.
- ☐ **C.** O local é para múltiplas séries; o global é para uma única série.
- ☐ **D.** O local exige o uso de SQL; o global exige o uso de MASE.

O que se entende por 'Cross-Learning' no contexto de previsão de séries temporais?

- ☐ **A.** A tradução automática de métricas de erro de escala para percentagem.
- ☐ **B.** A capacidade de um modelo local de validar dados de teste e treino em simultâneo.
- ☐ **C.** A aprendizagem de padrões globais a partir de múltiplas séries temporais distintas.
- ☐ **D.** O uso de features estáticas para prever variáveis dinâmicas.

Qual das seguintes métricas de erro é classificada como 'Resistente' a outliers mas 'Sofre com a escala'?

- ☐ **A.** MASE
- ☐ **B.** MAE
- ☐ **C.** RMSE
- ☐ **D.** MAPE

✓ 2 Statistical Forecasting Models

No contexto de modelos ARIMA, o que caracteriza especificamente uma série temporal estacionária?

- ☐ **A.** Possui uma taxa de crescimento linear constante, permitindo previsões baseadas em regressão simples.
- ☐ **B.** Apresenta ciclos sazonais perfeitamente previsíveis que se repetem em intervalos fixos.
- ☐ **C.** Apresenta uma média e variância constantes ao longo do tempo, sem tendências ou sazonalidade óbvias.
- ☐ **D.** É uma série onde a variância aumenta proporcionalmente ao valor da média temporal.

Ao realizar o Teste ADF (Dickey-Fuller), qual é a conclusão correta perante um p -value de 0.07?

- ☐ **A.** O modelo ARIMA deve obrigatoriamente incluir uma componente de média móvel (q).
- ☐ **B.** A série possui ruído branco e não pode ser modelada por métodos estatísticos.
- ☐ **C.** A série não é estacionária e necessita da aplicação de diferenciação (d).

- ☐ **D.** A série é considerada estacionária e está pronta para a modelagem direta.

Qual é a interpretação física da componente q (Média Móvel) num modelo ARIMA?

- ☐ **A.** Representa a dependência do valor atual em relação aos seus próprios valores passados.
- ☐ **B.** Representa a suavização exponencial aplicada aos dados mais recentes da série.
- ☐ **C.** Representa o número de subtrações necessárias para tornar a série estacionária.
- ☐ **D.** Representa a influência de choques ou erros aleatórios passados no valor presente.

No AutoARIMA, qual é o objetivo principal ao utilizar o critério AIC (Akaike Information Criterion)?

- ☐ **A.** Garantir que a série temporal seja diferenciada o máximo de vezes possível.
- ☐ **B.** Minimizar o erro absoluto médio independentemente do número de parâmetros.
- ☐ **C.** Encontrar um equilíbrio entre o ajuste aos dados e a simplicidade do modelo (parcimónia).
- ☐ **D.** Maximizar a complexidade do modelo para capturar todos os ruídos da série.

Diferente do ARIMA, qual é o princípio fundamental da filosofia da família de modelos ETS?

- ☐ **A.** Procura correlações diretas entre observações separadas por longos intervalos de tempo.
- ☐ **B.** Utiliza obrigatoriamente variáveis exógenas como temperatura e preço para a previsão.
- ☐ **C.** Exige que a série seja transformada em ruído branco antes da modelagem.
- ☐ **D.** Atribui maior peso às observações mais recentes através de suavização exponencial.

Um modelo ETS é definido pela tripla (E, T, S) . O que significa a componente T ser 'Amortecida' (A_d)?

- ☐ **A.** A tendência de crescimento ou queda perde força ao longo do horizonte de previsão.
- ☐ **B.** O modelo ignora completamente a tendência histórica da série.
- ☐ **C.** A tendência é removida através de uma diferenciação de primeira ordem.
- ☐ **D.** A tendência é multiplicativa em vez de aditiva.

Por que razão um modelo ETS com componente Multiplicativa (M) pode falhar ou 'partir'?

- ☐ **A.** Se a variância da série for perfeitamente constante ao longo do tempo.
- ☐ **B.** Se o número de observações for superior a 1000 pontos de dados.
- ☐ **C.** Se a série apresentar uma sazonalidade estritamente aditiva.
- ☐ **D.** Se a série temporal contiver valores iguais a zero ou valores negativos.

Ao utilizar um modelo ARIMAX para prever h passos no futuro, qual é o requisito obrigatório em relação aos regressores exógenos?

- ☐ **A.** É necessário fornecer os valores exatos dessas variáveis para todo o horizonte de previsão h .
- ☐ **B.** Os regressores devem ser calculados automaticamente pelo modelo durante a fase de treino.
- ☐ **C.** Apenas os valores históricos dos regressores são necessários para prever o futuro.
- ☐ **D.** As variáveis exógenas devem ter uma correlação de zero com a variável dependente.

Na análise de um gráfico PACF (Autocorrelação Parcial), o que indica um 'corte abrupto' após o primeiro lag (pico no lag 1 e o resto a zero)?

- ☐ **A.** Um modelo de Média Móvel de ordem 1 ($MA(1)$).
- ☐ **B.** Um modelo Autorregressivo de ordem 1 ($AR(1)$).
- ☐ **C.** A presença de uma sazonalidade anual muito forte.
- ☐ **D.** Que a série necessita de pelo menos duas diferenciações ($d = 2$).

Como se comporta o gráfico ACF (Autocorrelação) num processo de Média Móvel puro de ordem q ($MA(q)$)?

- ☐ **A.** Apresenta picos isolados apenas nos múltiplos do ciclo sazonal.
- ☐ **B.** Corta de repente após q lags significativos.
- ☐ **C.** Mantém todos os lags acima do nível de significância permanentemente.
- ☐ **D.** Decai suavemente de forma exponencial ou sinusoidal.

Se observar picos isolados nos lags 12, 24 e 36 de um gráfico ACF para dados mensais, qual é a suspeita diagnóstica?

- ☐ **A.** O modelo ARIMA deve ter a ordem $p = 36$.
- ☐ **B.** Existe uma sazonalidade anual ($s = 12$) que deve ser tratada (ex: SARIMA).
- ☐ **C.** A série temporal não possui qualquer componente modelável.
- ☐ **D.** A série é um ruído branco puro com variância inconstante.

Por que razão o método de Validação Cruzada (K -Fold) clássico é considerado um 'Erro Mortal' em séries temporais?

- ☐ **A.** Porque exige que todas as janelas de teste tenham o mesmo tamanho da média da série.
- ☐ **B.** Porque não permite o uso de variáveis exógenas no conjunto de teste.
- ☐ **C.** Porque demora demasiado tempo a processar grandes volumes de dados.
- ☐ **D.** Porque baralha a ordem dos dados, resultando em *Data Leakage* (usar o futuro para prever o passado).

Na técnica de Sliding Window (Janela Deslizante), qual é a regra de ouro sobre o posicionamento dos conjuntos de Treino e Teste?

- ☐ **A.** O Treino e o Teste podem sobrepor-se para maximizar o uso da informação.
- ☐ **B.** O conjunto de Teste deve sempre preceder o conjunto de Treino.

- ☐ **C.** O Treino desliza para a frente, mas o conjunto de Teste deve vir SEMPRE depois do Treino.
- ☐ **D.** A janela de Teste deve conter apenas o último valor disponível da série completa.

Qual é a configuração do parâmetro `step_size` que define uma validação cruzada do tipo 'Non-overlapping' (sem sobreposição de janelas de teste)?

- ☐ **A.** O `step_size` deve ser igual a 1 para testar todos os pontos possíveis.
- ☐ **B.** O `step_size` deve ser o dobro do número de janelas ($2 \times n_windows$).
- ☐ **C.** O `step_size` deve ser determinado automaticamente pela maximização da *Likelihood*.
- ☐ **D.** O `step_size` deve ser igual ao tamanho do horizonte de teste h .

Num modelo ARIMA, o que representa matematicamente a operação de diferenciação $\nabla y_t = y_t - y_{t-1}$?

- ☐ **A.** A normalização dos dados para uma escala entre 0 e 1.
- ☐ **B.** A média ponderada dos últimos dois valores da série.
- ☐ **C.** O erro de previsão acumulado desde o início da série.
- ☐ **D.** A variação ou mudança absoluta entre observações consecutivas.

Qual é a principal diferença entre os critérios AIC e BIC na seleção de modelos?

- ☐ **A.** O AIC foca na verosimilhança, enquanto o BIC foca apenas no erro quadrático médio.
- ☐ **B.** O AIC garante que o modelo nunca sofra de *Data Leakage*.
- ☐ **C.** O BIC penaliza modelos com mais parâmetros de forma mais rigorosa que o AIC.
- ☐ **D.** O AIC é usado apenas para ETS, enquanto o BIC é exclusivo para ARIMA.

O que indica a componente 'Erro' (E) num modelo ETS ser do tipo Aditivo (A)?

- ☐ **A.** A variância do erro é constante e independente do nível atual da série.
- ☐ **B.** O erro deve ser sempre um número positivo.
- ☐ **C.** O modelo falha se existirem zeros na série.
- ☐ **D.** A magnitude do erro aumenta à medida que o nível da série aumenta.

No diagnóstico visual de modelos ARIMA, se o ACF decair suavemente e o PACF cortar abruptamente no lag 2, qual o modelo sugerido?

- ☐ **A.** $ARIMA(0, d, 0)$
- ☐ **B.** $ARIMA(0, d, 2)$
- ☐ **C.** $ARIMA(2, d, 0)$
- ☐ **D.** $ARIMA(1, d, 1)$

Na prática de previsão, o que acontece se o utilizador não fornecer o futuro dos regressores num modelo ARIMAX?

- ☐ **A.** O modelo transforma-se automaticamente num $ETS(A, N, N)$.
- ☐ **B.** O modelo assume que o valor futuro é igual à média histórica.

- ☐ **C.** O modelo utiliza o último valor conhecido (y_t) para preencher as lacunas.
- ☐ **D.** O algoritmo gera um erro ou falha no momento do `predict`.

Ao analisar o gráfico de sazonalidade, o que distingue uma sazonalidade Multiplicativa (M) de uma Aditiva (A)?

- ☐ **A.** A sazonalidade Aditiva é a única que permite valores negativos.
- ☐ **B.** A sazonalidade Multiplicativa só ocorre em modelos ARIMA.
- ☐ **C.** A amplitude das oscilações sazonais aumenta ou diminui proporcionalmente ao nível da série.
- ☐ **D.** A sazonalidade Multiplicativa tem picos de altura constante independentemente da tendência.

Qual é a função do parâmetro `n_windows` na validação cruzada de séries temporais?

- ☐ **A.** Define o número de anos de dados necessários para uma previsão estável.
- ☐ **B.** Controla o número de variáveis exógenas permitidas no modelo.
- ☐ **C.** Define a largura total da janela de treino inicial.
- ☐ **D.** Indica quantos testes ou 'saltos' de validação serão realizados para avaliar o modelo.

Se um modelo AutoETS escolhe a combinação (M, A_d, M) , o que isso revela sobre a série temporal?

- ☐ **A.** A série é um ruído branco puro sem tendência.
- ☐ **B.** O modelo falhou em encontrar qualquer padrão e usou a configuração padrão.
- ☐ **C.** A série deve ser obrigatoriamente diferenciada antes da próxima previsão.
- ☐ **D.** A série tem erro multiplicativo, tendência que perde força e sazonalidade que escala com o nível.

Qual é a principal desvantagem de usar um `step_size` muito pequeno (ex: 1) numa Sliding Window?

- ☐ **A.** A componente de sazonalidade será apagada do diagnóstico visual.
- ☐ **B.** O modelo tornar-se-á estacionário automaticamente.
- ☐ **C.** Os resultados da validação serão altamente correlacionados entre si devido à grande sobreposição.
- ☐ **D.** É impossível calcular o AIC para passos pequenos.

No gráfico de diagnóstico visual, se o ACF decair suavemente e o PACF também decair suavemente, o que isto sugere?

- ☐ **A.** Um modelo misto ($ARMA/ARIMA$) com ambas as componentes p e q presentes.
- ☐ **B.** Um modelo AR puro.
- ☐ **C.** Um modelo MA puro.
- ☐ **D.** Que a série já é ruído branco.

O que acontece à variância numa série estacionária?

- ☐ **A.** Deve ser sempre igual a zero para garantir previsões perfeitas.

- ☐ **B.** A variância não tem relevância para a definição de estacionariedade.
- ☐ **C.** Deve aumentar exponencialmente para permitir o uso de modelos logarítmicos.
- ☐ **D.** Deve ser constante, significando que a dispersão dos dados é estável ao longo do tempo.

Qual é o critério de vitória utilizado pelo AutoETS para selecionar o melhor modelo?

- ☐ **A.** Minimizar o p -value do teste ADF.
- ☐ **B.** Garantir que a componente de Tendência seja sempre 'Aditiva'.
- ☐ **C.** Minimizar o número de lags no gráfico PACF.
- ☐ **D.** Maximizar a *Likelihood* (Verossimilhança).

✓ 3 Machine Learning Forecasting Models

No contexto do MLForecast, qual é a consequência imediata de não fornecer os valores de um Regressor Dinâmico (X_{df}) para todo o horizonte h no momento do predict?

- ☐ **A.** O modelo ML não consegue realizar a previsão para os passos em que os dados estão ausentes.
- ☐ **B.** O modelo assume automaticamente o valor médio histórico para os períodos em falta.
- ☐ **C.** O sistema utiliza o último valor conhecido (*Last Value Carried Forward*) para preencher a lacuna.
- ☐ **D.** A precisão do modelo diminui, mas a execução do pipeline de inferência continua normalmente.

Ao aplicar a 'Regra de Sobrevivência' para Transfer Learning (Abordagem Zero-Shot), por que razão o uso de variáveis categóricas locais (ex: ID_{Loja}) é proibido?

- ☐ **A.** Devido à necessidade de normalização global que impede o uso de *One-Hot Encoding*.
- ☐ **B.** Porque as redes neurais não conseguem processar dados categóricos nativamente.
- ☐ **C.** Para evitar que o *Early Stopping* Global interrompa o treino prematuramente devido ao ruído das categorias.
- ☐ **D.** Porque o modelo deve depender estritamente de padrões matemáticos universais (como *Lags*) para poder ser generalizado e aplicado diretamente num novo *dataset*.

Qual é a principal vantagem teórica da utilização de Conformal Prediction (CP) face aos métodos estatísticos tradicionais para calcular intervalos de confiança?

- ☐ **A.** O CP permite que modelos baseados em árvores, como o LightGBM, calculem probabilidades nativamente no `fit`.
- ☐ **B.** O CP adapta-se à realidade bruta dos dados sem exigir pressupostos teóricos sobre a curva de erros.

- ☐ **C.** O CP reduz automaticamente o erro médio (MAE) do modelo ao calibrar os quantis P10 e P90.
- ☐ **D.** O CP garante que os resíduos sigam sempre uma distribuição Gaussiana perfeita.

A técnica de 'LocalStandardScaler' é utilizada para resolver o problema de 'Cross-Learning'. Qual é a fórmula matemática correta aplicada a cada série id ?

- ☐ **A.** $z_t = y_t - y_{t-1}$
- ☐ **B.** $z = \frac{y - \mu_{id}}{\sigma_{id}}$
- ☐ **C.** $z = \frac{y - \min_{id}}{\max_{id} - \min_{id}}$
- ☐ **D.** $z = \frac{\text{lag}_1 - \text{lag}_7}{\mu_{id}}$

No pipeline do MLForecast, qual é o papel fundamental da função `predict()` em relação aos `target_transforms`?

- ☐ **A.** Aplicar as transformações de *Lags* (como *RollingMean*) aos dados de teste antes da previsão.
- ☐ **B.** Inverter automaticamente as transformações matemáticas para devolver a previsão na escala real e original.
- ☐ **C.** Calcular a média e o desvio padrão do horizonte de previsão para normalização local.
- ☐ **D.** Garantir que as linhas dos quantis P10 e P90 nunca se cruzem durante a inferência.

Durante a criação de Lags, o aparecimento de valores NaN (Not a Number) no início do *dataset* é inevitável. Qual é a recomendação do material para lidar com este problema?

- ☐ **A.** Utilizar o método `.fillna(method='bfill')` para propagar o primeiro valor conhecido para trás.
- ☐ **B.** Utilizar `.dropna()` antes do treino para não partir o modelo.
- ☐ **C.** Substituir os NaNs por zero para manter o volume total de dados.
- ☐ **D.** Ignorar os NaNs, pois algoritmos como XGBoost e LightGBM conseguem lidar com eles nativamente.

No contexto de 'Otimização Global', o que caracteriza o funcionamento do 'Early Stopping Global'?

- ☐ **A.** Interrompe o treino assim que a primeira janela de validação atinge o erro zero.
- ☐ **B.** Para a criação de novas árvores se o tempo de execução exceder o limite definido pelo hardware.
- ☐ **C.** Bloqueia a inclusão de novas séries temporais se estas aumentarem a variância do erro global.
- ☐ **D.** Aborta o treino automaticamente quando o erro médio entre todas as janelas de validação para de melhorar.

Como é desenhada a 'Mancha de Incerteza' utilizando ConformalPrediction?

- ☐ **A.** Através de uma simulação de Monte Carlo aplicada às folhas das árvores do LightGBM.
- ☐ **B.** Através da aplicação de um desvio padrão fixo calculado sobre todo o *dataset* de treino.
- ☐ **C.** Pela multiplicação do *Point Forecast* por um fator de risco R dependente do horizonte h .
- ☐ **D.** Utilizando a dispersão dos erros reais/empíricos que o modelo cometeu durante a validação cruzada.

No pipeline MLForecast, qual é a diferença conceptual entre **RollingMean** e **ExpandingMean**?

- ☐ **A.** **RollingMean** serve para normalização global e **ExpandingMean** para normalização local.
- ☐ **B.** **ExpandingMean** é obrigatoriamente aplicada antes da criação de *Lags* simples.
- ☐ **C.** **RollingMean** usa uma janela fixa de observações passadas, enquanto **ExpandingMean** utiliza todo o histórico disponível até àquele ponto no tempo.
- ☐ **D.** **RollingMean** foca-se na média do horizonte futuro, enquanto **ExpandingMean** foca-se no passado.

Sobre a 'Calibração de Intervalos', o que garante que o P50 (Mediana) esteja sempre 'blindado'?

- ☐ **A.** A utilização de Normalização Local que força todos os quantis para a mesma escala decimal.
- ☐ **B.** A aplicação de uma barreira física no código que impede o P50 de assumir valores negativos.
- ☐ **C.** A garantia matemática de que as linhas dos quantis (P_{10} , P_{50} , P_{90}) nunca se cruzam se o modelo for bem calibrado.
- ☐ **D.** O facto de ser calculado através da média aritmética simples dos erros de treino.

O 'Formato Obrigatório' (Long Format) para o MLForecast exige três colunas base. Quais são?

- ☐ **A.** **unique_id**, **ds**, **y**
- ☐ **B.** **unique_id**, **timestamp**, **target_value**
- ☐ **C.** **id_serie**, **data**, **valor**
- ☐ **D.** **series_id**, **date**, **labels**

Por que razão treinar milhares de séries ao mesmo tempo sem transformações de escala pode 'confundir' o algoritmo de Machine Learning?

- ☐ **A.** Porque o *Early Stopping Global* não funciona com séries de escalas diferentes.
- ☐ **B.** Pois o formato *Long Format* exige que todas as séries tenham a mesma amplitude de valores.
- ☐ **C.** Porque o algoritmo fica sem memória RAM para processar tantas séries em paralelo.

- ☐ **D.** Devido à dificuldade do modelo em distinguir padrões quando uma série vende 5 unidades e outra vende 5000.

Qual é a função do componente `LightGBM CV` no pipeline de otimização?

- ☐ **A.** Garantir que a matriz `X_df` seja limpa de valores nulos antes do treino.
- ☐ **B.** Treinar múltiplos *boosters* em paralelo em várias janelas de validação.
- ☐ **C.** Converter o modelo de Regressão em Classificação automaticamente.
- ☐ **D.** Substituir a necessidade de utilizar *Conformal Prediction* para prever o risco.

Ao utilizar a transformação `Differences(1)`, o que estamos a tentar remover da série temporal?

- ☐ **A.** A sazonalidade semanal.
- ☐ **B.** O ruído branco aleatório.
- ☐ **C.** A tendência, subtraindo o valor anterior.
- ☐ **D.** Os outliers ou valores extremos.

Na secção de Incerteza, o que é referido como o 'Calcanhar de Aquiles do ML'?

- ☐ **A.** A incapacidade de processar grandes volumes de dados (*Big Data*).
- ☐ **B.** O facto de modelos baseados em árvores cuspirem apenas *Point Forecasts* (valores únicos).
- ☐ **C.** O tempo excessivo gasto na etapa de *Feature Engineering*.
- ☐ **D.** A necessidade obrigatória de converter todos os dados para o formato *Long*.

✓ 4 Deep Neural Networks Forecasting Models

No contexto do paradigma global (cross-learning), qual é o principal risco associado ao treino de um único modelo em milhares de séries simultaneamente sem o uso de técnicas de escalonamento (scaling)?

- ☐ **A.** Ocorrência de *Vanishing* ou *Exploding Gradients*, levando ao colapso da rede e à estagnação dos pesos.
- ☐ **B.** Sobreajuste (*overfitting*) do modelo a uma única série temporal dominante no conjunto de dados.
- ☐ **C.** Incapacidade de capturar padrões globais devido à fragmentação dos pesos entre as séries.
- ☐ **D.** Aumento excessivo do tempo de inferência devido à complexidade linear do modelo MLP.

Qual é a distinção técnica fundamental entre o `local_scaler_type` e o `scaler_type` nas bibliotecas de NeuralForecast?

- ☐ **A.** O `local_scaler_type` apresenta melhor performance em horizontes longos por manter a escala original dos dados.
- ☐ **B.** O `local_scaler_type` é aplicado individualmente a cada série temporal (localmente), enquanto o `scaler_type` aplica uma normalização global ou a

nível de *dataset* completo.

- ☐ **C.** O `local_scaler_type` normaliza dinamicamente cada janela temporal (*window-based*) dentro do modelo durante o treino e inferência, enquanto o `scaler_type` realiza o escalonamento estático de cada série temporal completa de forma independente antes de alimentar as janelas ao modelo.
- ☐ **D.** O `scaler_type` foca-se apenas na média da série, enquanto o `local_scaler_type` foca-se na variância e na tendência.

Como é que o conceito de 'Residual Learning' é aplicado na arquitetura N-BEATS para melhorar a previsão?

- ☐ **A.** O modelo calcula o resíduo subtraindo o *Forecast* do *Backcast* em cada iteração de treino.
- ☐ **B.** Cada bloco tenta prever apenas o resíduo (erro) que o bloco anterior não conseguiu capturar.
- ☐ **C.** Cada bloco aprende a prever a tendência, deixando a sazonalidade como um resíduo para a camada de saída.
- ☐ **D.** A rede utiliza ligações residuais para saltar camadas e evitar o desaparecimento do gradiente em MLPs profundas.

Qual é a inovação introduzida pelo modelo N-HITS para resolver o problema da carga computacional em previsões de longo prazo (LSTF)?

- ☐ **A.** Redução do número de camadas da MLP para evitar o cálculo de gradientes pesados em horizontes longos.
- ☐ **B.** *Multi-rate Input Pooling*, que lê a série temporal em frequências diferentes através de blocos com taxas distintas.
- ☐ **C.** Uso de uma estrutura *Encoder-Decoder* baseada em LSTM para comprimir a memória de longo prazo.
- ☐ **D.** Substituição total das camadas lineares por mecanismos de *Auto-Correlation* baseados em FFT.

Na afinação de hiperparâmetros (*Hyperparameter Tuning*), qual é a 'Regra de Sobrevivência' crítica para evitar cair num Ótimo Local?

- ☐ **A.** Limitar o espaço de busca a 20 variáveis independentes para garantir a convergência.
- ☐ **B.** Garantir que a taxa de aprendizagem (*learning rate*) é ajustada a cada 20 épocas.
- ☐ **C.** A utilização exclusiva da ferramenta Optuna em detrimento do Ray Tune.
- ☐ **D.** O parâmetro `num_samples` deve ser obrigatoriamente superior a 20.

No mecanismo de *Self-Attention* do *Transformer*, qual é a função das matrizes Q (*Query*), K (*Key*) e V (*Value*)?

- ☐ **A.** Q e K são filtros de convolução e V é o mapa de características resultante.
- ☐ **B.** Q é o vetor de entrada, K é o peso da camada oculta e V é a previsão final.
- ☐ **C.** V define a importância temporal, enquanto Q e K lidam com a normalização dos dados.

- ☐ **D.** Q representa a pergunta ou o que estou a procurar, K representa as chaves de indexação ou o que o modelo possui, e V representa o conteúdo real da informação.

Qual é o impacto na complexidade computacional de um Transformer padrão se o tamanho do histórico (L) for duplicado?

- ☐ **A.** A complexidade linear faz com que o custo computacional apenas duplique.
- ☐ **B.** A complexidade quadrática $\mathcal{O}(L^2)$ faz com que o custo computacional quadruplique.
- ☐ **C.** O custo computacional permanece constante graças ao uso de *Multi-head Attention*.
- ☐ **D.** O custo aumenta logarithmicamente, seguindo a complexidade $\mathcal{O}(L \log L)$.

O modelo Informer utiliza um 'truque' chamado ProbSparse Attention. Qual é o principal ganho desta técnica?

- ☐ **A.** Permite prever a série temporal ponto a ponto para evitar a acumulação de erros.
- ☐ **B.** Garante que o modelo seja interpretável através de *Variable Selection Networks*.
- ☐ **C.** Reduz a complexidade de memória para $\mathcal{O}(L \log L)$ ao seleccionar apenas as ligações dominantes.
- ☐ **D.** Elimina a necessidade de *Positional Encoding* ao processar a série no domínio da frequência.

No modelo Autoformer, como é realizada a extração de tendências brutas de forma nativa?

- ☐ **A.** Utilizando um mecanismo de *Multi-rate Input Pooling* para observar diferentes frequências.
- ☐ **B.** Através do uso de *Mixture of Experts* (MoE) para seleccionar o melhor especialista em tendências.
- ☐ **C.** Através da decomposição de série (*Trend + Seasonality*) integrada dentro das suas próprias camadas.
- ☐ **D.** Substituindo a atenção tradicional por convoluções 1D de largo espectro.

Qual é a vantagem fundamental da técnica de 'Patching' introduzida pelo PatchTST?

- ☐ **A.** Permite que cada variável seja processada de forma dependente para maximizar o ruído entre canais.
- ☐ **B.** Transforma a série temporal numa imagem para utilizar Redes Neurais Convolucionais (CNNs).
- ☐ **C.** Garante que o modelo consiga prever incertezas nativas como P_{10} e P_{90} .
- ☐ **D.** Agrupa a série em blocos (*patches*), permitindo olhar para sub-sequências em vez de pontos isolados, o que reduz drasticamente a complexidade computacional e preserva a informação semântica local.

Por que motivo o Positional Encoding é considerado uma 'peça obrigatória' em arquiteturas Transformer para séries temporais?

- ☐ **A.** Para garantir que o modelo consiga lidar com séries de tamanhos variáveis através da normalização de camadas.
- ☐ **B.** É necessário para evitar o congelamento dos pesos (*Vanishing Gradients*) em sequências longas.
- ☐ **C.** Porque sem ele, a rede trata a sequência como um 'saco de números desordenados', perdendo a noção de ordem temporal.
- ☐ **D.** Serve para converter os valores da série temporal em frequências de senos e cossenos para o domínio de Fourier.

Em séries temporais, por que é que se prefere a Layer Normalization em vez da Batch Normalization?

- ☐ **A.** A *Layer Normalization* permite que o modelo ignore variáveis inúteis através do *Gated Residual Network* (GRN).
- ☐ **B.** A *Batch Normalization* causa o colapso da rede ao tentar normalizar os pesos compartilhados do paradigma global.
- ☐ **C.** A *Layer Norm* é mais rápida de calcular em GPUs devido à sua complexidade linear $\mathcal{O}(N)$.
- ☐ **D.** Porque a *Layer Norm* normaliza por instância e ao longo do eixo das características/tempo (linha a linha), lidando perfeitamente com sequências de tamanhos variáveis e evitando a dependência estatística entre amostras de um mesmo *batch*.

Qual é a função do componente 'Decoder' numa arquitetura LSTM (Encoder-Decoder)?

- ☐ **A.** Pega na 'memória comprimida' (vetores h_t e C_t) e projeta o vetor do futuro para h passos.
- ☐ **B.** Elimina o ruído da série temporal utilizando funções de ativação ReLU.
- ☐ **C.** Calcula a atenção multi-cabeça para focar em padrões específicos da série.
- ☐ **D.** Lê o passado e comprime a memória nos vetores *Hidden State* e *Cell State*.

No modelo TFT (Temporal Fusion Transformer), o que significa dizer que o output 'cospe incerteza nativa'?

- ☐ **A.** O modelo prevê múltiplos quantis (como P_{10} , P_{50} e P_{90}) em vez de apenas um único valor pontual (*Point Forecast*).
- ☐ **B.** O modelo indica a probabilidade de falha do gradiente durante o processo de treino.
- ☐ **C.** A rede gera várias previsões aleatórias e calcula a média aritmética entre elas.
- ☐ **D.** O output inclui um coeficiente de correlação de Pearson para cada passo de tempo previsto.

O modelo FEDformer opera puramente no 'Domínio da Frequência'. Qual é a principal ferramenta matemática utilizada para este fim?

- ☐ **A.** Transformadas de Fourier ou Wavelets.
- ☐ **B.** Matrizes de Adjacência para modelação de grafos.
- ☐ **C.** Derivadas parciais de segunda ordem (Hessianas).

- ☐ D. Regressão Logística polinomial de alta ordem.

Se um utilizador configurar o `num_samples` como 5 numa ferramenta de Auto Tuning como o Optuna, qual é o risco imediato?

- ☐ A. Risco alto de ficar preso num Ótimo Local, resultando num desempenho medíocre do modelo por falta de exploração do espaço de busca.
- ☐ B. O modelo irá sofrer de *Underfitting* severo devido à falta de dados de treino.
- ☐ C. Aumento exponencial do tempo de computação por cada amostra processada.
- ☐ D. Incompatibilidade com o motor Ray Tune, que exige um mínimo de 50 *samples*.

Na arquitetura N-BEATS, qual é o objetivo do componente 'Backcast'?

- ☐ A. Prever os valores futuros da série temporal com base no histórico fornecido.
- ☐ B. Ajustar os pesos da rede através de *backpropagation* durante a fase de treino.
- ☐ C. Tentar reconstruir o passado para verificar quanto da informação original foi capturada pelo bloco, permitindo calcular o resíduo a passar para o bloco seguinte.
- ☐ D. Inverter a ordem da série temporal para capturar dependências de longo prazo.

O que acontece na Multi-Head Attention quando múltiplas 'cabeças' leem a série em paralelo?

- ☐ A. Aumenta-se a complexidade para $\mathcal{O}(L^4)$ para garantir a precisão máxima.
- ☐ B. O modelo escolhe a melhor cabeça de atenção e descarta as restantes para poupar memória.
- ☐ C. As cabeças competem entre si num sistema de '*Winner-Takes-All*' para atualizar os pesos.
- ☐ D. Cada cabeça pode focar-se em aspetos diferentes (sub-espacos de representação distintos), como tendências longas, volatilidade diária ou padrões específicos de sazonalidade.

Qual das seguintes afirmações sobre o modelo TFT (Temporal Fusion Transformer) é verdadeira no que toca à sua explicabilidade?

- ☐ A. A sua explicabilidade advém apenas da visualização direta dos pesos da *Multi-head Attention*.
- ☐ B. É considerado uma 'caixa negra' impenetrável devido ao uso de *Gated Residual Networks*.
- ☐ C. Utiliza *Variable Selection Networks* (VSN) para identificar quais as variáveis de entrada (estáticas e dinâmicas) que realmente importam para a previsão.
- ☐ D. Não permite o uso de variáveis externas (exógenas) para manter a simplicidade da interpretação.

Qual é a 'Equação Mágica' que define a Atenção num Transformer clássico?

- ☐ A. $\frac{\text{Softmax}(V)}{QK^T} \times \sqrt{d_m}$
- ☐ B. $\text{Softmax}\left(\frac{QK^T}{\sqrt{d_m}}\right) \times V$
- ☐ C. $\text{Sigmoid}(QK^T) \times V^2$
- ☐ D. $\text{Softmax}(Q + K + V) \times \sqrt{d_m}$

No N-HITS, a solução para previsões de longo prazo envolve três tipos de blocos. Quais são eles?

- ☐ A. Bloco Rápido (detalhes), Bloco Médio (padrões semanais) e Bloco Lento (tendências macro).
- ☐ B. Bloco de Entrada, Bloco Oculto e Bloco de Saída.
- ☐ C. Bloco de Tendência, Bloco de Sazonalidade e Bloco de Ruído.
- ☐ D. Bloco Linear, Bloco Recorrente e Bloco de Atenção.

Qual é a principal função da ferramenta Ray Tune ou Optuna mencionada no Quadro 7?

- ☐ A. Reduzir a complexidade quadrática dos Transformers para linear.
- ☐ B. Automatizar a afinação de hiperparâmetros para encontrar a configuração de melhor desempenho.
- ☐ C. Gerar dados sintéticos para aumentar o tamanho do conjunto de treino.
- ☐ D. Visualizar as previsões em tempo real através de *dashboards* interativos.

Em relação à MLP (Perceptron Simples) no contexto de séries temporais, qual é uma característica fundamental apresentada no diagrama?

- ☐ A. Possui uma memória intrínseca capaz de comprimir o histórico em estados ocultos.
- ☐ B. Resolve nativamente o problema de *Vanishing Gradients* em horizontes longos.
- ☐ C. Utiliza um mecanismo de *Multi-rate Input Pooling* para processar frequências.
- ☐ D. É uma das fundações clássicas que utiliza frequentemente a função de ativação ReLU.

Como o PatchTST lida com múltiplas séries temporais (canais) simultaneamente?

- ☐ A. Através do *Channel-Independence*, lendo cada variável isoladamente no *backbone* para evitar ruído entre canais.
- ☐ B. Utilizando uma *Variable Selection Network* (VSN) para desligar canais inúteis.
- ☐ C. Concatenando todos os canais num único vetor de entrada antes da atenção.
- ☐ D. Aplicando uma Transformada de Fourier diferente para cada canal em paralelo.

No modelo N-HITS, qual o resultado esperado ao aplicar esta arquitetura em horizontes de previsão longos?

- ☐ A. A necessidade obrigatória de usar *Positional Encoding* para ordenar as frequências.

- ☐ **B.** Uma redução na precisão em troca de uma maior interpretabilidade dos blocos residuais.
- ☐ **C.** Um modelo muito mais leve, rápido e preciso no longo prazo.
- ☐ **D.** Um aumento significativo no tempo de treino devido ao processamento de múltiplas frequências.

A deconstrução do erro no N-BEATS significa que o Bloco 2 não tenta prever tudo de novo. O que é que ele tenta prever?

- ☐ **A.** Tenta prever os valores da série temporal original mas com os pesos invertidos.
- ☐ **B.** Tenta prever a incerteza estatística da previsão feita pelo Bloco 1.
- ☐ **C.** Tenta prever a tendência global, enquanto o Bloco 1 foca apenas no ruído.
- ☐ **D.** Tenta prever apenas a 'fração de erro' (o resíduo) que o Bloco 1 falhou em capturar.