

FUNDAMENTOS DE TEXT MINING E ANÁLISE DE SENTIMENTOS

1 TIPOLOGIA DE DADOS E CONCEITOS BASE

-   • **Dados Estruturados:** Organizados com estrutura rígida (Bases de Dados Relacionais, tabelas, sistemas ERP).
-   • **Dados Semi-estruturados:** Sem estrutura de BD relacional, mas contêm marcadores de organização (ficheiros XML, OWL, RDF).
-     • **Dados Não-estruturados:** ~90% da informação na Web. Sem estrutura predefinida (Texto, e-mails, redes sociais, imagens, áudio, dados de sensores/IoT).

 **Alerta Moodle:** Identificar sensores IoT e emails como não-estruturados e ficheiros XML como semi-estruturados.

-  • **KDD** (Knowledge Discovery in Databases): Processo global de extração de padrões novos e válidos.
-  • **Data Mining (DM):** Fase específica dentro do KDD (aplicação de algoritmos).
-  • **Text Mining (KDT):** Processamento computacional de texto para extrair conhecimento de dados não-estruturados.

 **Alerta Moodle:** KDD não é sinónimo de DM. DM é contido dentro do KDD.



2 ÁREAS E TAREFAS COMPUTACIONAIS

-  • **Information Retrieval (IR):** Recuperação de documentos relevantes num universo de documentos (Ex: Motor de busca).
-  • **Information Extraction (IE):** Extração de informação específica (entidades, relações) de dentro de um documento já recuperado.
-  • **Natural Language Processing (NLP):** Limpeza e pré-processamento de dados linguísticos.
-  • **NER (Identificação de Entidades Nomeadas):** Extrai classes específicas (Pessoas, Países, Datas, Doenças/Genes).
-  • **Sumarização Extrativa:** Algoritmo seleciona frases exatas do texto original. “ ”
-  • **Sumarização Abstrativa:** Algoritmo gera novas frases usando aprendizagem supervisionada. ☁

 **Alerta Moodle:** Distinção rígida entre IR (documento inteiro) e IE (dados dentro do documento), e entre sumarização que copia (extrativa) e sumarização que cria (abstrativa).

3 CLASSIFICAÇÃO E SENTIMENTO

-  • **Classificação de Texto:** Tarefa de aprendizagem supervisionada baseada num conjunto pré-definido de categorias.
-  • **Opinião vs. Facto:** Factos expressam informação objetiva. Opiniões expressam informação subjetiva (crenças, avaliações pessoais).
-  • **Polaridade:** Classificação dicotomizada/trinária de texto em Positivo, Negativo ou Neutro.



- **Modelos de Emoção:** Classificações alternativas baseadas em Ekman (6 emoções base) ou Plutchik (roda de emoções em pares opostos).



4 DESAFIOS TÉCNICOS E PREDITIVOS (CRÍTICOS)

-  • **Ruído nos Dados:** Chatwords, abreviaturas, erros ortográficos, emojis.
-  • **Sensibilidade de Contexto / Ambiguidade:** A classificação de um termo depende da semântica envolvente (Ex: “Laranja” pode ser cor, fruta ou partido).
-  • **Similaridade Semântica:** Termos diferentes com o mesmo significado (Ex: “Automóvel” e “Viatura”).



Automóvel ↔ Viatura

 **Alerta Moodle - Negação:** Tratamento de dupla negação (Ex: “Não é mau”) inverte a polaridade expectável.

“Não é mau” → 😊

 **Alerta Moodle - Ironia/Sarcasmo:** O maior desafio da análise. Utilização explícita de léxico positivo para expressar um estado de insatisfação técnica (Ex: “Perfeito! Avariou no primeiro dia”).

“Perfeito! Avariou no primeiro dia” → 😞