

ANÁLISE EXPLORATÓRIA DE DADOS (PANDAS & VISUALIZAÇÃO)

1 IMPORTAÇÃO E CONFIGURAÇÃO DE VISUALIZAÇÃO (PANDAS)



- **Leitura de Dados:** A função `pd.read_csv()` é utilizada para carregar um ficheiro CSV para um DataFrame.

```
df = pd.read_csv('dados.csv')
```



- **Configuração `display.max_colwidth`:** Definir como `None` garante que o texto completo das colunas (ex: tweets) é mostrado sem ser truncado.

```
pd.set_option('display.max_colwidth', None)
```



- **Configuração `display.expand_frame_repr`:** Definir como `False` evita que as colunas sejam quebradas em diversas linhas no ecrã.

```
pd.set_option('display.expand_frame_repr', False)
```



- **Filtro de Colunas:** A sintaxe `df[['col1', 'col2']]` cria um novo DataFrame apenas com as colunas selecionadas.

```
df_filtrado = df[['col1', 'col2']]
```

2 FUNÇÕES DE EXPLORAÇÃO (FOCO ALTO PARA EXAME)



- **Método `.info()`:** Retorna informação estrutural: número de linhas e colunas, tipos de dados (Dtype), contagem de valores não nulos e o uso de memória.

```
df.info()
RangeIndex: 1000 entries, 0 to 999
Data columns (total 4 columns):
#   Column      Non-Null Count  Dtype
---  -
0    id          1000 non-null   int64
1    text        1000 non-null   object
2    sentiment   950 non-null    object
3    score       1000 non-null   float64
memory usage: 31.4+ KB
```



- **Método `.describe()`:** Retorna informação estatística. Para colunas numéricas dá a média, desvio-padrão, mínimos, máximos e quartis. Para texto (objetos), dá o total, valores únicos, o valor mais frequente (top) e a sua frequência.

```
df.describe(include='all')

```

	count	unique	top	freq			
text	1000	985	ótimo	5			
sentiment	950	3	Neutro	510			
score	1000	NaN	NaN	NaN			
count	mean	std	min	25%	50%	75%	max
score	1000	0.12	0.85	-0.95	-0.45	0.10	0.99



- **Método `.value_counts()`:** Retorna o número de elementos únicos numa coluna e exclui automaticamente os valores nulos.

```
df['sentiment'].value_counts()
Neutro    510
Positivo  280
Negativo  160
Name: sentiment, dtype: int64
```




Alerta Moodle: Trocar a definição de `.info()` com `.describe()`. Se a pergunta falar em "uso de memória" ou "valores não nulos", a resposta é `.info()`. Se falar em "desvio-padrão" ou "estatísticas", é `.describe()`.

3 VISUALIZAÇÃO GRÁFICA (SEABORN & MATPLOTLIB)




- **Pie Chart (`plt.pie`):** Gráfico de pizza ideal para visualizar a distribuição percentual/proporcional de categorias (ex: sentimentos).

Distribuição de Sentimentos




- **Countplot (`sns.countplot`):** Gráfico de barras automático que conta quantas vezes cada categoria aparece numa única coluna especificada no eixo X.

Contagem por Sentimento




Alerta Moodle (Parâmetro `hue`): No countplot, o parâmetro `hue` separa os dados dentro de cada barra principal por uma segunda categoria, recorrendo a cores diferentes (ex: barras de companhias aéreas divididas por cor de sentimento).

Companhias Aéreas por Sentimento



- **Barplot (`sns.barplot`):** Gráfico de barras manual onde é necessário especificar explicitamente os dados do eixo X e do eixo Y.

Score Médio por Companhia Aérea



4 WORDCLOUDS (NUVENS DE PALAVRAS)



- **Pré-requisito Crítico:** Para gerar uma WordCloud, é necessário criar uma única String contendo todas as palavras da coluna de texto, separadas por espaços.

```
texto_completo = ' '.join(df['text'].dropna().astype(str))
```



- **Parâmetro `collocations = False`:** Evita combinações de palavras (bigramas) na nuvem gerada, garantindo que apresenta apenas palavras isoladas.

```
WordCloud(collocations=False, ...)
```



- **Parâmetro `interpolation='bilinear'`:** Utilizado no método `plt.imshow()` para tornar a exibição da imagem da nuvem de palavras mais suave.

```
plt.imshow(wordcloud, interpolation='bilinear')
```



Alerta Moodle: Afirmar que a WordCloud aceita diretamente uma coluna do DataFrame ou uma lista. Falso: tem de ser agregada (ex: através do método `.join()`) numa única String antes de ser processada.

Nuvem de Palavras (Exemplo)

