

NLP e PRÉ-PROCESSAMENTO COMPUTACIONAL DE TEXTO

1 CONCEITOS BASE DE NLP E TEXT MINING

- NLP (Processamento de Linguagem Natural):**
Subárea da IA focada em converter linguagem humana para a máquina. Divide-se em três análises:



LÉXICA:

Extraí significad-/ categoria gramatical.



SINTÁTICA:


Identifica relações e dependências.



SEMÂNTICA:

Desambiguação pelo contexto.

- CORPUS vs. TOKEN:** O texto individual é partido em TOKENS (palavras elementares). O conjunto de múltiplos documentos analisados chama-se CORPUS (plural: Corpora).



2 PIPELINE DE PRÉ-PROCESSAMENTO (Foco Prático e Teórico)



NER (Reconhecimento de Entidades Nomeadas):

Categoriza tokens em classes rígidas (Pessoas, Organizações/ORG, Datas, Países/Cidades/GPE).

Exemplo:

John works at Google in Lisbon on 2024-05-10
PER ORG GPE DATE



POS Tagging (Part-of-Speech):

Análise léxica que atribui etiquetas gramaticais a cada palavra (Nome, Verbo, Adjetivo, Preposição).

Exemplo:

The quick brown fox jumps over the lazy dog
DET ADJ ADJ NOUN VERB ADP DET ADJ NOUN



Remoção de Stopwords:

Eliminação de palavras que servem apenas de ligação e não são discriminantes (ex: the, at, and, de, para). Não acrescentam valor ao modelo preditivo.

Exemplo:

Texto original: the movie was great and very exciting
Sem stopwords: movie great exciting



Tokenização (Atomização):

A quebra do texto. Pode usar espaços, regras ou modelos estatísticos (ex: word_tokenize do NLTK).

Exemplo (word_tokenize):

"Hello, world! 😊 It's great :-)"
→ ['Hello', ',', 'world', '!', '😊', 'It', 's', 'great', ':-)']



ALERTA MOODLE (Regex):

Na remoção de pontuação com o método `str.replace(r'[^\w\s]+', '')`, o código remove tudo o que não seja letra, número (\w) ou espaço (\s).



ALERTA MOODLE (Negação):

O tratamento da negação costuma envolver procurar advérbios (ex: "not") e substituir a palavra seguinte pelo seu antônimo, apagando a palavra de negação.

Ex: "not good" → "bad" / "evil"



NORMALIZAÇÃO DO RUÍDO:

Antes de tokenizar, é fundamental transformar emojis em texto (demojize), expandir emoticons :-) para happy face e chatwords (LOL para laugh out loud).

😂 → laughing face :-) → happy face LOL → laugh out loud

3 STEMMING vs. LEMATIZAÇÃO

(A maior armadilha de exame)



STEMMING (Radicalização):

Corta os prefixos e sufixos da palavra de forma agressiva para chegar à raiz (ex: interchangeable → interchang). Usa frequentemente o Algoritmo de Porter.

Exemplos (Porter Stemmer)

Palavra Original	Stem
interchangeable	interchang
running	run
studies	studi
happiness	happi



LEMATIZAÇÃO (Lematização):

Retorna o "lema" (a forma de dicionário da palavra). É semanticamente rigoroso e gera sempre palavras válidas (ex: saw → see, better → good).

Exemplos (Lemmatization)

Palavra Original	Lema
saw	see
better	good
running	run
mice	mouse



ALERTA MOODLE (Stemming):

Causa frequentemente perda de informação semântica, pois palavras diferentes podem colapsar no mesmo radical truncado, que pode sequer ser uma palavra válida do dicionário.


4 SELEÇÃO DE ATRIBUTOS (Feature Selection)



Objetivo:

Filtrar o vocabulário, mantendo apenas as palavras (features) mais informativas para distinguir as classes (ex: positivo vs. negativo), reduzindo as dimensões da matriz Term-Document.

Matriz Term-Document (Alta Dimensionalidade)



Matriz Term-Document (Reduzida)



Técnicas Comuns:

Modelos baseados em filtro usam testes estatísticos para medir a relação termo-classe (feature ↔ classe).

Qui-quadrado (chi2)


Correlação de Pearson

Information Gain

5 BALANCEAMENTO DE DATASETS

- Problema:** Um dataset é desbalanceado quando a classe "Maioritária" (ex: 6000 reviews negativas) tem muito mais exemplos que a "Minoritária" (ex: 1500 positivas), causando overfitting.

Antes (Desbalanceado)



Após (Balanceado)



Undersampling (Subamostragem):

Resolve-se eliminando observações aleatórias da classe majoritária para igualar a minoritária (replace=False no Pandas).



Oversampling (Sobreamostragem):

Resolve-se duplicando/adicionando observações na classe minoritária para igualar a majoritária (replace=True).



ALERTA MOODLE: Não inverter os conceitos!

UNDER corta o excesso do MAIOR. OVER multiplica e repete o MENOR.