

➤ CRIAÇÃO DE MODELOS: REPRESENTAÇÃO, CLASSIFICAÇÃO E MÉTRICAS ➤

1 MODELOS DE REPRESENTAÇÃO DE TEXTO



- **Bag-of-Words (BoW):** Representação em matriz (Documento-Termo) onde cada linha é um documento e cada coluna é um termo.
Booleano: Regista apenas a presença (1) ou ausência (0) do termo.



Alerta Moodle (Limitações do BoW):

Gera uma matriz muito esparsa (cheia de zeros), ignora completamente a ordem das palavras e não captura a semântica ou relação entre elas.



- **Term-Frequency (TF):** Conta o número de ocorrências de cada termo no documento, sendo normalizada pelo tamanho do documento para não beneficiar textos longos.

tf-idf

- **TF-IDF (Term Frequency - Inverse Document Frequency):** Mede a relevância real de um termo num documento face a toda a coleção.

Fórmula base: $tfidf(t,d,D) = tf(t,d) \cdot idf(t,D)$



Alerta Moodle (O segredo do IDF):

O modelo beneficia palavras raras. Um termo que aparece muito num documento específico, mas raras vezes nos restantes documentos da coleção, ganha um peso maior.



- **Word Embeddings:** Abordagem vetorial que captura o contexto, semântica e sintaxe da palavra. Palavras com significados semelhantes ficam localizadas próximas umas das outras no espaço dimensional.

Exemplo BoW (Booleano)

	filme	bom	mau	lento
Doc 1	1	1	0	0
Doc 2	1	0	1	1
Doc 3	0	1	0	1


Exemplo TF (Normalizado)

	filme	bom	mau	lento
Doc 1	0.33	0.33	0	0
Doc 2	0.25	0	0.25	0.25
Doc 3	0	0.50	0	0.50

Exemplo TF-IDF

	filme	bom	mau	lento
Doc 1	0.21	0.18	0	0
Doc 2	0.15	0	0.22	0.28
Doc 3	0	0.50	0	0.35

Exemplo (espaço 2D)




2 PARADIGMAS DE MACHINE LEARNING



- **Aprendizagem Supervisionada (Classificação / Regressão):** O algoritmo aprende através de exemplos pré-classificados (dados etiquetados/labeled data).
 - Se o objetivo é prever uma classe finita (Positivo/Negativo) chama-se **Classificação**.
 - Se prevê um valor contínuo, chama-se **Regressão**.


Classificação

(ex: Positivo/Negativo)




Regressão

(ex: Prever Preço)



- **Aprendizagem Não-Supervisionada:** Não existem exemplos previamente classificados. O modelo agrupa dados apenas por semelhança (ex: Clustering).

Exemplo: Clustering



Alerta Moodle (Desafios do Modelo Supervisionado):

- **Overfitting:** Ajustamento excessivo do modelo aos dados de treino, falhando ao prever novos dados.
- **Cross-Validation (K-fold):** Técnica usada exatamente para evitar o overfitting. Divide o total de dados em K subconjuntos para alternar entre treino e teste.



Algoritmos Comuns de Classificação:



Naïve Bayes



Logistic Regression



K-NN



Decision Trees



Redes Neurais

3 AVALIAÇÃO DO MODELO (Matriz de Confusão e Métricas)

- **Matriz de Confusão:**

Valores Reais

	Valores Reais	
	Positivo (1)	Negativo (0)
Previsões do Modelo		
Positivo (1)	TP (Verdadeiro Positivo) Acerto	FP (Falso Positivo) Erro Tipo I Falso Alarme
Negativo (0)	FN (Falso Negativo) Erro Tipo II Omissão	TN (Verdadeiro Negativo) Acerto

- **TP (Verdadeiro Positivo):** Classificou Positivo e era Positivo (Acerto).
- **TN (Verdadeiro Negativo):** Classificou Negativo e era Negativo (Acerto).
- **FP (Falso Positivo - Erro Tipo I):** Classificou Positivo, mas era Negativo (Falso Alarme).
- **FN (Falso Negativo - Erro Tipo II):** Classificou Negativo, mas era Positivo (Omissão).

- **Accuracy (Exatidão):** Total de acertos a dividir pelo total de casos.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Recall (Sensibilidade):** Capacidade de identificar todos os positivos reais.

$$Recall = \frac{TP}{TP + FN}$$

- **Precision (Precisão):** Avalia se as previsões positivas estavam corretas.

$$Precision = \frac{TP}{TP + FP}$$

- **F1-Score:** Média harmónica entre a Precision e o Recall.

$$F\text{-score} = \frac{2 \cdot Recall \cdot Precision}{Recall + Precision}$$

- **Specificity:** Taxa de identificação dos negativos reais.

$$Specificity = \frac{TN}{TN + FP}$$

- **Kappa de Cohen:** Mede a concordância descartando o fator acaso. Varia entre 0 e 1 (onde 1 é a concordância perfeita e <0 indica que não há qualquer concordância).

$$\kappa = \frac{p_o - p_e}{1 - p_e}$$

onde p_o = acordo observado
 p_e = acordo esperado por acaso

4 APLICAÇÃO E PREVISÃO



Pipeline Obrigatório:

Para prever o sentimento de um texto novo, o comentário tem primeiro de passar pelo mesmo pré-processamento e usar exatamente o mesmo vocabulário da matriz (vetorização) usada no treino do modelo.



Texto Novo

"O serviço foi ótimo, mas a comida é cara."



Pré-processamento
(mesmo do treino)

[serviço, ótimo, comida, cara]



Vetorização
(mesmo vocabulário)

[0, 1, 0, 0, 1, 0, 0, ...]



Modelo Treinado
(classificador)



Previsão

Sentimento: POSITIVO