

LLMs, TRANSFORMERS E DEEP LEARNING

1 IA GENERATIVA (GenAI) E LLMs

- IA Generativa: Subárea da IA que cria novos conteúdos (texto, imagens, código, áudio).

LLMs (Large Language Models):

Modelos em grande escala baseados em Redes Neurais Profundas (Deep Learning) focados exclusivamente no processamento e geração de texto.

Alerta Moodle (Desvantagens críticas):

- Alucinações:** O modelo "inventa" factos ou apresenta desinformação com elevada confiança.
- Escalonamento e Latência:** Exigem elevado custo computacional (GPUs) e têm tempos de resposta elevados.
- Enviesamento (Bias):** Herdam os preconceitos presentes nos dados de treino originais.

4 ENCODER vs. DECODER (Mapeamento Direto para Exame)

Encoder (Codificador):

Processa o texto de forma bidirecional (lê o contexto antes e depois da palavra simultaneamente). Ideal para compreender texto.



- Exemplos / Uso: BERT, DistilBERT, ROBERTa. Usado em classificação, análise de sentimento e extração de entidades (NER).

Decoder (Descodificador):


Processa o texto de forma sequencial prevendo o token seguinte apenas com base no contexto anterior (histórico). Ideal para gerar texto.



- Exemplos / Uso: GPT (ChatGPT, DistilGPT2). Usado em geração de texto, sentence completion e tradução.

Encoder-Decoder:

Combina ambos. Transforma o formato "texto entrada → texto saída".




- Exemplo / Uso: Modelo T5.

2 WORD EMBEDDINGS (A evolução da vetorização)

Conceito:

Representação de palavras como vetores densos num espaço multidimensional. Captura o contexto sintático e a semântica (ao contrário do TF-IDF e BoW). Palavras com significados semelhantes ficam próximas no espaço vetorial.



Alerta Moodle (Estáticos vs. Contextualizados):

Static Embeddings (Word2Vec, GloVe):

A mesma palavra tem sempre o mesmo vetor, independentemente da frase.
Ex: "banco" (instituição) e "banco" (jardim) têm a representação exata.

Contextualized Embeddings (BERT, GPT, LLaMA):

O vetor da palavra muda consoante o contexto da frase em que está inserida.

3 ARQUITETURA TRANSFORMERS (A Revolução de 2017)

Mecanismo de Atenção (Self-Attention):

Permite ao modelo focar-se e modelar relações entre palavras muito afastadas num texto, compreendendo as dependências de longo alcance.



Alerta Moodle (Transformers vs. RNNs/LSTMs):

Ao contrário dos modelos antigos que processavam a informação **sequencialmente** (palavra a palavra, perdendo contexto longo), os **Transformers** permitem **paralelização** (processam a frase toda ao mesmo tempo), o que aumenta a velocidade de treino e a captura de contexto.

RNNs / LSTMs (Sequencial)



Lento e perde contexto longo

Transformers (Paralelo)



Rápido e captura contexto longo

5 FINE-TUNING E HIPERPARÂMETROS (Decoração Obrigatória)



Fine-Tuning (Ajuste Fino):

Reutilizar um modelo pré-treinado em volumes massivos de dados genéricos e ajustá-lo com treino adicional num conjunto de dados específico (ex: reviews de companhias aéreas).

Alerta Moodle (Os parâmetros de treino):



Epochs (Épocas): → Número de vezes que o algoritmo passa por todo o conjunto de treino.

Poucas épocas = **Underfitting** (não aprende o suficiente).



Batch Size (Lote): → O número de exemplos processados antes de o modelo atualizar os seus pesos.

Muitas épocas = **Overfitting** (decora os dados e perde a capacidade de generalizar).



Loss Function (Função de Perda): → Mede o erro entre a previsão e a realidade. → Quanto menor, melhor.



Early Stopping: → Técnica de paragem que aborta o treino automaticamente quando a Loss no conjunto de validação começa a piorar (evita o overfitting).